

PROYECTO – IMPLEMENTACIÓN DE UN SISTEMA DE CLASIFICACIÓN DE RESULTADOS DE ANÁLISIS DE ACEITE USADO PARA MOTORES DE MAQUINARIA PESADA EN LA INDUSTRIA MINERA

Ing. Daniel Arturo Martínez Morales

Aspirante a título de maestría MIAD, Universidad de los Andes

Ing. Luis Miguel Ortega Cañate

Aspirante a título de maestría MIAD, Universidad de los Andes

ABSTRACT

The project aims to automate and optimize the oil analysis process used to assess the condition of critical fleet components. Currently, each reliability analyst spends an average of 15 hours per week processing results, with 58% of that time dedicated to manual sample evaluation, failure mode assignment, and severity classification. This operational burden, combined with the variability inherent to individual judgment, contributes to annual losses of approximately \$500 kUSD due to the late identification of abnormal conditions that evolve into functional failures.

The proposed solution integrates advanced analytics and automation tools to reduce processing times, standardize diagnostics, and enhance early detection of risk conditions. The initiative seeks to strengthen operational reliability, reduce economic losses associated with undetected failures, and establish a more efficient, consistent, and data-driven predictive maintenance process.

RESUMEN

El proyecto tiene como objetivo automatizar y optimizar el proceso de análisis de aceite utilizado en la evaluación de la condición de componentes críticos de la flota. Actualmente, cada analista de confiabilidad dedica en promedio 15 horas semanales al procesamiento de resultados, destinando el 58% de ese tiempo al análisis manual de muestras, asignación de modos de falla y determinación de severidad. Esta carga operativa, sumada a la variabilidad asociada al criterio individual, contribuye a que se presenten pérdidas anuales cercanas a \$500 kUSD derivadas de la identificación tardía de condiciones anómalas que evolucionan hacia fallas funcionales.

La solución propuesta implementa herramientas de analítica avanzada y automatización para disminuir los tiempos de procesamiento, estandarizar los diagnósticos y mejorar la detección temprana de condiciones de riesgo. Con ello se busca fortalecer la confiabilidad operacional, reducir pérdidas económicas por fallas no detectadas oportunamente y consolidar un proceso de mantenimiento predictivo más eficiente, consistente y basado en datos.

REPOSITORIO EN GIT: <https://github.com/darturo12/Tesis-de-Grado-MIAD->

Nota de Confidencialidad

El presente documento contiene información técnica, operativa y analítica basada en datos internos suministrados por la organización colaboradora. Dichos datos, así como los resultados, modelos, hallazgos y conclusiones aquí desarrollados, son estrictamente confidenciales y han sido utilizados únicamente con fines académicos y de análisis interno del proyecto.

Queda prohibida la reproducción, divulgación, distribución o uso parcial o total de la información contenida en este documento sin la autorización previa y por escrito de la organización propietaria de los datos. Cualquier uso no autorizado podrá constituir una infracción a las políticas internas de la empresa y a la normativa aplicable en materia de manejo de información sensible.

El contenido de este informe no debe ser interpretado como una publicación oficial ni como un documento destinado a circulación externa.

Tabla de Contenido

Nota de Confidencialidad	2
Contexto del problema de negocio	5
Planteamiento del problema de negocio	5
Traducción al problema de Analytics	6
Coherencia Modelos–Requerimientos	6
Alternativas de Modelos y Plan de Pruebas	7
Verificación de Supuestos y Tratamiento Previo de Datos	8
Técnicas de limpieza de datos	14
Tratamiento de datos faltantes	14
Rango de Valores numéricos de las variables en el dataset y validez	16
Tratamiento a Outlier	16
Entendimiento de los datos posterior a la aplicación de técnicas de limpieza	19
Desbalance de Clases	20
Ingeniería de Variables SACODE	21
Preprocesamiento según Tipo de Modelo	25
Entrenamiento, Validación y Calibración de Modelos de clasificación de modo de falla	25
Selección de Variables	25
Esquema de Entrenamiento y Validación	26
Parametrización de los Modelos	26
Métricas de Evaluación y su Justificación	27
Análisis de Resultados y Selección de Modelos	27
Resultados del Pipeline Global (todas las flotas)	27
Resultados por Flota	28
Resultados de enfoque unificado con flota como Feature	29
Ajustes Implementados	34
Desarrollo de modelo de clasificación de severidad	34
Componentes Pendientes y Plan de Implementación	37
Componentes Pendientes de Implementación	37
Plan de Implementación del Prototipo Funcional	37
Definición de reglas para la prescripción de acciones de mantenimiento	38
Referencias	40

Tabla de ilustraciones

Ilustración 1, Matriz de correlación de datos faltantes	11
Ilustración 2, Análisis de distribución de variables numéricas	12
Ilustración 3, Análisis comparativo de medias de variables numéricas frente a las clases de la variable "Severidad"	13
Ilustración 4, Matriz de correlación posterior al tratamiento de datos.....	17
Ilustración 5, Análisis de distribución de variables numéricas posterior al tratamiento de los datos	19
Ilustración 6, Análisis comparativo de medias de variables numéricas frente a las clases de la variable "Severidad" posterior al tratamiento de datos	20
Ilustración 7, Distribución de predictores por flota	22
Ilustración 8, Resultados de severidad SACODE por flota	23
Ilustración 9, Tablas de contingencia para contrastar resultados de reglas SACODE vs Criterio del analista	24
Ilustración 10, Resultados de la primera iteración (Todas las flotas).....	28
Ilustración 11, Resultados del enfoque unificado sobre la muestra de Test	29

Listado de tablas

Tabla 1, Enfoques analíticos necesarios según los requerimientos de negocio.....	7
Tabla 2, Modelos de machine learning a ser explorados.....	8
Tabla 3, Descripción de variables del conjunto de datos	9
Tabla 4, Esquema de tratamiento de datos faltantes	15
Tabla 5, Análisis de validez de rango de las variables numéricas	16
Tabla 6, Esquema de tratamiento de datos atípicos	16
Tabla 7, Configuración general de la validación cruzada implementada	26
Tabla 8, Hiperparámetros por modelo	26
Tabla 9, Resultados luego de Validación cruzada.....	29
Tabla 10, Resumen de comparación de modelos luego de enfoque unificado	33
Tabla 11, Planificación de actividades futuras.....	37
Tabla 12, Acciones recomendadas para cada combinación de criterios de modos de falla y criticidad	38

Contexto del problema de negocio

En la industria minera, el mantenimiento de maquinaria pesada como camiones OHT y excavadoras es crítico para garantizar la continuidad operativa y evitar interrupciones de alto costo. Entre las herramientas predictivas más utilizadas, el análisis de aceite usado permite evaluar el estado de salud de componentes mecánicos, detectar contaminación, desgaste acelerado y degradación del lubricante, anticipándose a fallas funcionales que pueden comprometer la disponibilidad de la flota.

Sin embargo, la interpretación de estos análisis depende en gran medida del criterio experto de los analistas de confiabilidad. Actualmente, cada analista invierte en promedio 15 horas semanales en el procesamiento de resultados, destinando el 58% de ese tiempo al análisis manual de muestras, la asignación de modos de falla y la determinación del nivel de severidad. Este proceso, altamente dependiente del juicio individual, introduce variabilidad en los diagnósticos, genera tiempos de respuesta prolongados y reduce la capacidad para identificar oportunamente condiciones críticas. Como consecuencia, la organización enfrenta pérdidas anuales cercanas a \$500 kUSD asociadas a fallas que no fueron detectadas a tiempo debido a evaluaciones manuales tardías o inconsistentes.

En este contexto, surge la necesidad de desarrollar un proyecto de analítica avanzada que permita integrar, procesar y modelar los datos de análisis de aceite para identificar comportamientos anómalos y tendencias de deterioro. Este proyecto busca fortalecer la estrategia de mantenimiento predictivo de la organización, alineándose con los objetivos corporativos de eficiencia operacional, reducción de costos y transición hacia decisiones basadas en datos (data-driven). Además, responde a una oportunidad estratégica: aprovechar las capacidades analíticas internas y el conocimiento técnico del equipo de confiabilidad para crear modelos que no solo mejoren el rendimiento de los activos actuales, sino que sienten las bases para la transformación digital de la gestión de activos dentro del holding.

Con el fin de abordar esta problemática, el proyecto tiene como propósito desarrollar un modelo analítico basado en modelos de aprendizaje supervisado que permita automatizar la detección e interpretación de modos de falla a partir de los resultados históricos del análisis de aceite. El modelo integrará la metodología SACODE como marco de interpretación estandarizada para clasificar muestras, identificar comportamientos anómalos y priorizar alertas de mantenimiento predictivo.

Planteamiento del problema de negocio

La interpretación manual de los resultados de análisis de aceite usado presenta varios desafíos:

- Alta dependencia del juicio experto y de la disponibilidad del analista. Los analistas solo están presentes en la operación de lunes a viernes mientras que los resultados de nuevas muestras se generan todos los días.
- Inconsistencias en las evaluaciones debidas a diferencias de experiencia o criterio técnico. La organización ha reportado que el tiempo de promedio que le toma a un analista luego del entrenamiento básico para llegar a formar un criterio experto es de cerca de 3 años.
- Retrasos en la entrega de resultados y en la toma de decisiones de mantenimiento. Los lunes (primer día laboral de la semana para los analistas) se reportan lo mayores numero de muestras sin análisis, situación que se normaliza a mediados de semana, esto genera

que muestras cuyos resultados fueron emitidos el sábado por la tarde terminan siendo analizadas por el analista el miércoles.

- Subutilización de la información generada por los análisis, que podría alimentar sistemas avanzados de diagnóstico y pronóstico.
- Altos tiempos entre el procesamiento de la muestra y generación de recomendaciones con base en los hallazgos identificados.

En virtud de lo anterior, se requiere un sistema automatizado que permita clasificar de forma consistente y rápida las muestras de aceite usado según criterios estandarizados (metodología SACODE de Noria), indicando el estado del aceite, el nivel de contaminación y el desgaste, además de establecer un nivel de severidad y sugerir acciones básicas de mitigación.

El proyecto de analytics tiene como propósito desarrollar un modelo analítico basado en modelos de aprendizaje supervisado que permita automatizar la detección e interpretación de modos de falla a partir de los resultados históricos del análisis de aceite. El modelo integrará la metodología SACODE como marco de interpretación estandarizada para clasificar muestras, identificar comportamientos anómalos y priorizar alertas de mantenimiento predictivo.

Las técnicas potenciales de Analytics a emplear comprenden:

- **Modelos de aprendizaje automático supervisados** para la clasificación de estados del aceite y predicción de modos de falla.
- **Análisis de importancia de predictores** para identificar el impacto de cada variable en la falla estimada y así comprender los factores de mayor influencia en el deterioro de los motores.
- **Visualizaciones interactivas / Storytelling** para la visualización de los resultados obtenidos del modelo clasificación y análisis descriptivos.

Traducción al problema de Analytics

El proyecto de analytics tiene como propósito desarrollar un modelo analítico basado en modelos de aprendizaje supervisado que permita automatizar la detección e interpretación de modos de falla a partir de los resultados históricos del análisis de aceite. El modelo integrará la metodología SACODE como marco de interpretación estandarizada para clasificar muestras, identificar comportamientos anómalos y priorizar alertas de mantenimiento predictivo.

Las técnicas potenciales de Analytics a emplear comprenden:

- **Modelos de aprendizaje automático supervisados** para la clasificación de estados del aceite y predicción de modos de falla.
- **Análisis de importancia de predictores** para identificar el impacto de cada variable en la falla estimada y así comprender los factores de mayor influencia en el deterioro de los motores.

Coherencia Modelos–Requerimientos

Pregunta Central de Negocio.

¿Cómo automatizar la clasificación de resultados de análisis de aceite usado en motores de maquinaria pesada para reducir la variabilidad diagnóstica, mejorar la detección oportuna de condiciones anómalas y disminuir las pérdidas operativas asociadas (~500 kUSD/año)?

Esta pregunta se descompone en tres subproblemas analíticos que corresponden a tres tipos de análisis distintos, cada uno atendido por un componente específico de la herramienta a desarrollar:

Tabla 1, Enfoques analíticos necesarios según los requerimientos de negocio

Pregunta Analítica	Requerimiento del Negocio	Tipo de Análisis	Componente Para Implementar	Métricas Para Considerar
¿Cuál es el estado actual del componente?	Clasificación primaria según metodología SACODE (Salud, Contaminación, Desgaste) con niveles Normal / Advertencia / Crítico.	Descriptivo– Basado en reglas	Caculo de limites condenatorios basados en comportamiento estadístico de los predictores de Salud, Contaminación, Desgaste	% De similitud entre las muestras clasificadas bajos los criterios de Noria y clasificadas por los Analistas de confiabilidad
¿Qué severidad tendrá esta muestra?	Clasificación de la severidad del componente (Normal / Warning / Critical) con el fin de priorizar intervenciones de mantenimiento y reducir el tiempo promedio de diagnóstico de 36 horas a 12 horas.	Predictivo supervisado	Desarrollo de modelos de aprendizaje supervisado tomando como variable objetivo `Assigned Condition Rating`, con 25 variables predictoras (21 numéricas + 4 categóricas SACODE)	Métricas para evaluar en los modelos entrenados. 1. AUC 2. Reccall 3. Preccision 4. Accuracy
¿Qué modo de falla presenta el componente?	Clasificación de modos de falla según metodología SACODE/Noria, identificando el tipo de anomalía para orientar la acción correctiva.	Predictivo supervisado	Entrenamiento de modelos de aprendizaje supervisado tomando como variable objetivo `Fault Effect`, con 25 variables predictoras (21 numéricas + 4 categóricas SACODE)	Métricas para evaluar en los modelos entrenados. 1. AUC 2. Reccall 3. Preccision 4. Accuracy
¿Qué recomendación brindar en pro de restablecer la condición del componente?	Generar recomendaciones técnicas enforçadas según el modo de falla y severidad de la condición para restablecer la condición del activo.	Prescriptivo– Basado en reglas	Generación de recomendaciones a partir de la combinación de severidad y modo de falla predichos, el sistema consulta una tabla de reglas definida con el área de confiabilidad y despliega una recomendación de acción	% De recomendaciones aceptadas por los analistas de confiabilidad.

Alternativas de Modelos y Plan de Pruebas

El problema a resolver corresponde a una tarea de clasificación supervisada con enfoque predictivo, por lo que las técnicas candidatas incluyen árboles de decisión, Random Forest, Gradient Boosting, y redes neuronales.

Inicialmente, se aplicará un enfoque exploratorio descriptivo para identificar correlaciones entre variables y patrones históricos de falla. Posteriormente, se utilizarán modelos supervisados para la

clasificación de SACODE y severidad. Las técnicas de interpretación de modelos, como SHAP values, se emplearán para explicar la importancia de cada variable y facilitar la trazabilidad de los resultados.

Se propone un conjunto de seis algoritmos candidatos para satisfacer el requerimiento de clasificación multiclase. La selección de estas alternativas obedece a la variedad de enfoques estadísticos que representan y a su pertinencia para datos tabulares con desbalance de clases.

Tabla 2, Modelos de machine learning a ser explorados.

Modelo	Ventajas	Desventajas
Regresión Logística	Interpretable, rápida de entrenar, sirve como línea base sólida.	Asume relaciones lineales entre predictores; puede ser insuficiente para patrones complejos.
Random Forest	Robusto ante outliers, no requiere escala, captura no linealidades, ofrece importancia de variables.	Puede sobre ajustar con datos muy desbalanceados si no se ajusta el peso de clases.
XGBoost	Alto desempeño en datos tabulares, regularización incorporada, maneja bien el desbalance con scale_pos_weight.	Requiere calibración cuidadosa de hiperparámetros; mayor tiempo de entrenamiento.
LightGBM	Más veloz que XGBoost en conjuntos grandes, buena generalización, soporta class_weight.	Puede ser menos estable que XGBoost en conjuntos muy pequeños.
SVM (kernel RBF)	Efectivo en espacios de alta dimensión, buena separación de márgenes.	Costoso computacionalmente en datasets grandes; sensible a la escala de variables.
MLP (Red Neuronal)	Captura relaciones no lineales complejas, flexible en arquitectura.	Requiere mayor volumen de datos; difícil de interpretar; propenso a sobreajuste sin early stopping.

Adicionalmente, se exploró una variante de Regresión Logística con reducción de dimensionalidad mediante PCA, con el objetivo de evaluar si la compresión del espacio de características mejoraba la capacidad discriminativa del modelo lineal. Esta alternativa se incluyó en el plan de pruebas como caso de comparación.

El plan de pruebas contempla la evaluación de todos los modelos bajo el mismo esquema de validación cruzada estratificada de 5 folds sobre el conjunto de entrenamiento balanceado, seguido de una evaluación final sobre el conjunto de prueba con la distribución de clases original (sin balanceo), garantizando así una estimación realista del desempeño en producción.

Verificación de Supuestos y Tratamiento Previo de Datos

A continuación, se presenta el análisis exploratorio de los datos obtenidos para el desarrollo de un Sistema Clasificador de Resultados de Análisis de Aceite Usado en Motores de Maquinaria Pesada.

Los datos aportados corresponden a los resultados de los análisis de aceite usado de motores de maquinaria pesada en los últimos 2 años de la organización. Los datos provienen del sistema ERP corporativo, que consolida de manera diaria los resultados de laboratorio de los análisis de aceite usado. Cada registro incluye variables numéricas (concentraciones de metales de desgaste, propiedades fisicoquímicas, contaminantes y aditivos) y variables categóricas (modo de falla, severidad, tipo de componente, marca y modelo del equipo).

Esta información fue suministrada en un solo archivo CSV y proviene de la base de datos de análisis del cliente, esta base de datos contiene toda la información necesaria para el desarrollo del sistema clasificador que se propone en el presente trabajo.

A continuación, se describen las columnas del conjunto de datos provisto:

Tabla 3, Descripción de variables del conjunto de datos

COLUMNA	DESCRIPCIÓN
Component ID	Identificación del componente
Asset ID	Identificación del activo (ID de la maquinaria)
Flota	Grupo de activos al que pertenece la maquinaria
Location	Grupo de activos en la base de datos de análisis de resultados de aceite usado
Component Profile	Identificación del perfil de límites que usa la base datos para análisis basado en reglas
Lubricant	Descripción del tipo de lubricante
Connection Code	Llave primaria del registro en la base de datos de análisis
Observation Type	Identificación del tipo de registro, para este caso todos son registros de análisis de fluidos
Observation Date	Fecha de toma de la muestra de aceite
Observation Code	ID del registro
Meter Reading	Lectura del medidor de servicio del componente al momento de la toma de muestra
All Time Meter Reading	Lectura del medidor de servicio de la maquinaria al momento de la toma de muestra
Component Age	Horas de servicio del componente
Observation Interval	Horas de servicio desde la última muestra de aceite para el mismo componente y maquinaria
days	Días desde la última muestra de aceite para el mismo componente y maquinaria
Observation Rating	Clasificación preliminar de severidad de la condición
Rule Based Rating	Clasificación automática realizada por el software de análisis
Lube Age	Horas de servicio del lubricante
Live	Vida del activo
Lube Drained	Indica si el lubricante fue cambiado en la última intervención del equipo
Added	Cantidad de aceite completado al componente
Assigned Condition Rating	Severidad asignada por el analista
Condition Review Notes	Notas de la revisión realizada por el analista
Further Recommendations	Recomendaciones adicionales dadas por el analista
Fault Effect	Selección del modo de falla
Reviewed	Fecha de revisión
Reviewer	Persona que realizó la revisión
Action Summary	Lista de acciones para el analista
Boro (ppm)	Contenido de boro en partes por millón (ppm)
Calcio (ppm)	Contenido de calcio en partes por millón (ppm)
Cinc (ppm)	Contenido de zinc en partes por millón (ppm)
Fosforado (ppm)	Contenido de fósforo en partes por millón (ppm)
Magnesio (ppm)	Contenido de magnesio en partes por millón (ppm)
Molibdeno (ppm)	Contenido de molibdeno en partes por millón (ppm)
SILICATOS (ppm)	Contenido de silicatos en partes por millón (ppm)
Agua (%)	Contenido de agua en porcentaje (%)
Dilución por combustible (%)	Contenido de combustible en porcentaje (%)
Hollín JOAP (Abs/cm)	Contenido de hollín en la muestra de aceite medido en absorbancia por centímetro (ABS/cm)
Nitración JOAP (Abs/cm)	Contenido de nitración en la muestra de aceite medido en absorbancia por centímetro (ABS/cm)
Oxidación JOAP (Abs/cm)	Contenido de oxidación en la muestra de aceite medido en absorbancia por centímetro (ABS/cm)
Silicio (ppm)	Contenido de silicio en partes por millón (ppm)
Sodio (ppm)	Contenido de sodio en partes por millón (ppm)
Sulfatación JOAP (Abs/cm)	Contenido de sulfatación en la muestra de aceite medido en absorbancia por centímetro (ABS/cm)
Viscosidad @ 100°C (cSt)	Viscosidad del aceite a 100°C
ISO 4406	999 > 04µ: Contenido de partículas mayores a 4 micras por cada mililitro de lubricante
ISO 4406	999 > 06µ: Contenido de partículas mayores a 6 micras por cada mililitro de lubricante
ISO 4406	999 > 14µ: Contenido de partículas mayores a 14 micras por cada mililitro de lubricante
Aluminio (ppm)	Contenido de aluminio en partes por millón (ppm)
Bario (ppm)	Contenido de bario en partes por millón (ppm)
Cadmio (ppm)	Contenido de cadmio en partes por millón (ppm)

Cobre (ppm)	Contenido de cobre en partes por millón (ppm)
Cromo (ppm)	Contenido de cromo en partes por millón (ppm)
Estaño (ppm)	Contenido de estaño en partes por millón (ppm)
Hierro (ppm)	Contenido de hierro en partes por millón (ppm)
Níquel (ppm)	Contenido de níquel en partes por millón (ppm)
Partículas Ferrosas (ppm)	Contenido de partículas ferrosas en partes por millón (ppm)
Plomo (ppm)	Contenido de plomo en partes por millón (ppm)
Color del Refrigerante	Indicador del color del refrigerante (Para muestras de refrigerante)
Glycerin (%)	Porcentaje de glicerina en el refrigerante (Para muestras de refrigerante)
Nitrito (ppm)	Contenido de nitritos en partes por millón (ppm) (Para muestras de refrigerante)
PUNTO DE EBULLICION (°C)	Punto de ebullición del refrigerante (Para muestras de refrigerante)
Sólidos Totales Disueltos (ppm)	Contenido de sólidos en suspensión en partes por millón (ppm) (Para muestras de refrigerante)
Turbidez (NTU)	Indicador de la turbidez del refrigerante (Para muestras de refrigerante)
pH	Potencial de hidrogeno pH de la muestra de refrigerante (Para muestras de refrigerante)
Titanio (ppm)	Contenido de titanio en partes por millón (ppm)
Vanadio (ppm)	Contenido de vanadio en partes por millón (ppm)

Algunas preguntas que pueden hacerse para un entendimiento inicial de los datos son:

¿Qué significa o como puede entenderse cada fila del dataframe?

Cada fila representa un resultado de análisis de aceite conteniendo la información de identificación de la muestra y de los resultados puntuales de diferentes pruebas de laboratorio a los que el lubricante usado es sometido para revelar sus propiedades y contenido de elementos de interés para estimar el estado de "salud" de la maquinaria en términos de modos de falla potenciales y el grado de severidad.

¿Qué tamaño tiene el conjunto de datos?

En la muestra de datos compartida se tiene un total de 4297 registros y 66 columnas. Todos los registros corresponden a muestras de aceite de motores de maquinaria pesada.

¿Qué tipos de datos tienen las columnas del conjunto de datos?

Se tiene un total de 46 columnas numéricas (45 de tipo flotante y 1 de tipo entero), los 20 restantes son columnas categóricas de tipo object. Esto permite conocer que el dataframe es mayoritariamente numérico.

¿Qué se encontró a nivel de completitud y cardinalidad?

Los anteriores resultados indican que se tiene un número importante de columnas prácticamente vacías, con un porcentaje de faltantes igual o cercano a 100%. Entre ellas se tienen:

- Titanio (ppm)
- Níquel (ppm)
- Cadmio (ppm)
- ISO 4406:1999 > 04μ
- Bario (ppm)
- ISO 4406:1999 > 14μ
- SILICATOS (ppm)
- PUNTO DE EBULLICION (°C)
- Glycerin (%)
- Color del Refrigerante
- pH

- Turbidez (NTU)
- Nitrito (ppm)
- Sólidos Totales Disueltos (ppm)
- Lube Age
- Action Summary

Por otra parte, también se tienen columnas con una cardinalidad muy baja, algunas incluso con cardinalidad igual a 1 lo que las hace inútiles para la construcción de modelos predictivos, tal es el caso de:

- Added
- Color del Refrigerante
- Observation Type
- Lube Drained
- Location
- Lubricant

Estas columnas al estar vacías o poseer una única categoría o valor deberán ser eliminadas del conjunto de datos.

También se realizó una revisión de la correlación de los datos faltantes haciendo uso de la librería de missingno





Ilustración 1, Matriz de correlación de datos faltantes

De esta matriz se puede establecer algunas conclusiones como sigue:

- Hay bloques de columnas con correlaciones cercanas a 1.0, lo que indica que faltan juntas porque pertenecen al mismo proceso o análisis de laboratorio.
- El grupo de variables de metales y contaminantes (Calcio, Zinc, Magnesio, etc.) forma un bloque claro: si falta una, faltan todas.
- Las variables del paquete JOAP (Hollín, Nitración, Oxidación, Sulfatación) también muestran correlaciones casi perfectas entre sí.

- También se realizó un entendimiento inicial de los datos a partir de las distribuciones de las variables y su relación con una de las variables objetivo, la severidad asignada por el analista de confiabilidad.



- La mayoría de las variables muestran distribuciones fuertemente sesgadas a la derecha.
 - Hay colas largas y presencia evidente de outliers extremos en múltiples variables (metales, JOAP, sólidos disueltos, sodio, silicio, etc.).

- Esto sugiere procesos con valores excepcionales, pero poco frecuentes, típicos de análisis de aceite contaminado o en falla.
- Outliers extremos: hay valores aislados muy altos en varios contaminantes y lecturas temporales; se debe verificar si representan fallas reales o errores de medición.
- Variables con valores casi nulos o detección limitada: varios metales (Bario, Cadmio, Níquel, Vanadio, Titanio, etc.) concentran la mayoría de observaciones igual es a cero o cercanas a cero con pocos valores detectables, posible límite de detección del instrumento
- Histogramas planos o vacíos indican alta falta de datos o constantes: ISO 4406 y algunas trazas muestran prácticamente ninguna variación, esto debido a que se trata de datos faltantes en su mayoría.
- Las variables relacionadas con tiempo o uso del equipo tienen gran dispersión.




Ilustración 3, Análisis comparativo de medias de variables numéricas frente a las clases de la variable "Severidad"

- Incremento progresivo hacia “Critical”: En la mayoría de los parámetros (metales, JOAP, sólidos, viscosidad, partículas), los valores promedio aumentan al pasar de Normal → Warning → Critical, validando la coherencia del sistema de clasificación. Estas variables terminan siendo fuertes candidatos a ser indicadores tempranos de desgaste o contaminación.
- JOAP (Hollín, Oxidación, Nitración, Sulfatación): Exhiben el patrón más consistente y marcado: valores significativamente más altos en Warning y, sobre todo, Critical. Son variables clave para modelar condición del aceite.
- Algunos metales con valores muy bajos: Muchos permanecen en cero o valores muy bajos en todas las categorías, lo cual limita su valor discriminante para estratificación de condición.

Técnicas de limpieza de datos

Posteriormente al entendimiento de los datos, se siguió con el proceso de limpieza de los datos, para esta fase el apoyo y acompañamiento del cliente son de vital importancia ya que con base en la experiencia y entendimiento del negocio y de los datos se toman las decisiones que impactaran positiva o negativamente la solución analítica a desarrollar

Inicialmente se eliminan del conjunto de datos aquellas variables que no tienen que ver con el análisis planteado, como aquellas que se utilizan en el análisis de refrigerante y las que se usan en el análisis de aceite hidráulico.

Variables irrelevantes para el análisis actual

Algunas columnas no aportan información útil para el estudio de condición del lubricante de los motores Diesel, ya sea porque:

- Representan metadatos administrativos
- Son información redundante
- No tienen relación directa con las variables físico-químicas a analizar

Ejemplos: Added, Lube Drained, Live, Lube Age, Observation Date, Observation Code, Observation Type, Observation Interval, Meter Reading, All Time Meter Reading, Component ID, Location, Asset ID, Connection Code, Lubricant, Component Profile, Component Age, All Time Meter Reading

Estas columnas no contienen información relevante que permita la identificación de modos de fallas generadas en el análisis de aceite, es por esta razón que las variables son excluidas de dataset con el cual se trabajara. En el caso de variables como Lube Drained, Lube Age, Component Age, en consultas con el cliente este ha expresado que en esta fase los datos contenidos en las columnas mencionadas no son confiables debido a problemas de sincronización entre diversos softwares que tienen en operación, se espera que en posibles desarrollos posteriores ya se cuente con esta información e incluirlas como variables de entrenamiento al modelo.

Tratamiento de datos faltantes

Con base en los datos faltantes identificados, se concuerda una reunión con el cliente en donde se definen las siguientes acciones bajo los datos faltantes entregada.

Tabla 4, Esquema de tratamiento de datos faltantes

Variable	% Faltantes	¿Por qué se genera?	¿Se requiere para el desarrollo del modelo?	¿Se elimina?	¿Qué tratamiento se les dará a los datos faltantes?
Action Summary	91.71515	No todos los analistas documentan acciones en el ERP; se usa otra base de datos	No	Sí	Se elimina la columna
Partículas Ferrosas (ppm)	70.351408	No en todos los motores se mide por tiempos de laboratorio	Deseable	Sí	Se elimina la variable según aprobación del cliente
Fosforado (ppm)	69.979055	Inconsistencias operativas	Sí	No	Imputación por mediana
Cinc (ppm)	69.979055	Problemas de digitación o identificación	Sí	No	Imputación por mediana
Further Recommendations	66.185711	Campo no diligenciado por todos; trazabilidad en otro software	No	Sí	Se elimina
Estaño (ppm)	28.48499	Antes no se medía; ahora sí	Sí	No	Imputación por mediana
Viscosidad @ 100°C (cSt)	7.679777	Baja disponibilidad del instrumento	Sí	No	Imputación por mediana
Boro (ppm)	4.305329	Problemas de digitación o identificación	Sí	No	Imputación por mediana
Hollín JOAP (Abs/cm)	3.002094	Problemas de digitación o baja disponibilidad	Sí	No	Imputación por mediana
Dilución por combustible (%)	2.746102	Problemas operativos	Sí	No	Imputación por mediana
Agua (%)	2.466837	Baja disponibilidad del instrumento	Sí	No	Imputación por mediana
Oxidación JOAP (Abs/cm)	2.280661	Baja disponibilidad del instrumento	Sí	No	Imputación por mediana
Nitración JOAP (Abs/cm)	2.280661	Baja disponibilidad del instrumento	Sí	No	Imputación por mediana
Sulfatación JOAP (Abs/cm)	2.280661	Baja disponibilidad del instrumento	Sí	No	Imputación por mediana
Calcio (ppm)	1.81522	Problemas de digitación o identificación	Sí	No	Imputación por mediana
Magnesio (ppm)	1.81522	Problemas de digitación o identificación	Sí	No	Imputación por mediana
Molibdeno (ppm)	1.768676	Problemas operativos	Sí	No	Imputación por mediana
Silicio (ppm)	1.768676	Problemas operativos	Sí	No	Imputación por mediana
Sodio (ppm)	1.768676	Problemas operativos	Sí	No	Imputación por mediana
Aluminio (ppm)	1.768676	Problemas operativos	Sí	No	Imputación por mediana
Cromo (ppm)	1.768676	Problemas operativos	Sí	No	Imputación por mediana
Cobre (ppm)	1.768676	Problemas operativos	Sí	No	Imputación por mediana
Plomo (ppm)	1.768676	Problemas operativos	Sí	No	Imputación por mediana
Hierro (ppm)	1.117058	Problemas operativos	Sí	No	Imputación por mediana
Reviewer	0.79125	Errores de sincronización del ERP	No	Sí	Se elimina
Condition Review Notes	0.511985	No todos los analistas lo llenan	No	Sí	Se elimina
Reviewed	0.302537	Errores de sincronización	No	Sí	Se elimina
Assigned Condition Rating	0	Sin faltantes	Sí	No	Se mantiene
Fault Effect	0	Sin faltantes	Sí	No	Se mantiene
Trakka Rating	0	Sin faltantes	No	Sí	No relevante para el modelo
Observation Rating	0	Sin faltantes	No	Sí	No relevante para el modelo
Flota	0	Sin faltantes	Sí	No	Se mantiene

Rango de Valores numéricos de las variables en el dataset y validez

Una vez definidos los criterios para el tratamiento de los datos faltantes, se procede a revisar los rangos de valores observados durante la exploración del dataset proporcionado por el cliente. A partir de este análisis, se establecen las siguientes conclusiones.

Tabla 5, Análisis de validez de rango de las variables numéricas

Variable	Mínimo	Máximo	Comentario
Boro (ppm)	0	395,44	Valido
Calcio (ppm)	1,66	5411	No valido, valores de calcio presentan niveles a 1000, Posible Outlier
Cinc (ppm)	495,99	2154	No valido, valores de Cinc presentan niveles a 1000, Posible Outlier
Fosforado (ppm)	0	1542	No valido, valores de Fosforo presentan niveles a 1000, Posible Outlier
Magnesio (ppm)	3,16	2256	Valido
Molibdeno (ppm)	0	121,13	Valido
Agua (%)	0	14	Valido
Dilución por combustible (%)	0	10	Valido
Hollín JOAP (Abs/cm)	0	62	Valido
Nitración JOAP (Abs/cm)	0	14	Valido
Oxidación JOAP (Abs/cm)	0	33	Valido
Silicio (ppm)	0,55	95,54	Valido
Sodio (ppm)	0,17	2556	Valido
Sulfatación JOAP (Abs/cm)	0	39	Valido
Viscosidad @ 100°C (cSt)	3,431	19,4	Valido
Aluminio (ppm)	0	6,66	Valido
Cobre (ppm)	0,01	274,2	Valido
Cromo (ppm)	0	7,07	Valido
Estaño (ppm)	0	2,96	Valido
Hierro (ppm)	0	265,38	Valido
Plomo (ppm)	0	60,32	Valido

Tratamiento a Outlier

A partir de los outliers identificados mediante el método del rango intercuartílico (IQR), utilizando el umbral estándar de 1.5 veces el rango, se procede a cuantificar la cantidad de valores atípicos detectados en cada variable. Con esta información, se definen las acciones a seguir, las cuales serán acordadas y validadas conjuntamente con el cliente

Tabla 6, Esquema de tratamiento de datos atípicos

Variable	# Outlier	¿Se deben eliminar o Imputar?
Magnesio (ppm)	947	Si se deben imputar por los valores de mediana
Dilución por combustible (%)	530	No, Outlier corresponden a fallas, no se deben eliminar o imputar
Calcio (ppm)	455	Si se deben imputar por los valores de mediana

Plomo (ppm)	414	No, Outlier corresponden a fallas, no se deben eliminar o imputar
Aluminio (ppm)	357	No, Outlier corresponden a fallas, no se deben eliminar o imputar
Cobre (ppm)	340	No, Outlier corresponden a fallas, no se deben eliminar o imputar
Hierro (ppm)	336	No, Outlier corresponden a fallas, no se deben eliminar o imputar
Cromo (ppm)	297	No, Outlier corresponden a fallas, no se deben eliminar o imputar
Silicio (ppm)	263	No, Outlier corresponden a fallas, no se deben eliminar o imputar
Sodio (ppm)	258	No, Outlier corresponden a fallas, no se deben eliminar o imputar
Hollín JOAP (Abs/cm)	200	No, Outlier corresponden a fallas, no se deben eliminar o imputar
Estaño (ppm)	102	No, Outlier corresponden a fallas, no se deben eliminar o imputar
Molibdeno (ppm)	88	Si se deben imputar por los valores de mediana
Sulfatación JOAP (Abs/cm)	83	No, Outlier corresponden a fallas, no se deben eliminar o imputar
Oxidación JOAP (Abs/cm)	68	No, Outlier corresponden a fallas, no se deben eliminar o imputar
Viscosidad @ 100°C (cSt)	60	No, Outlier corresponden a fallas, no se deben eliminar o imputar
Boro (ppm)	41	No, Outlier corresponden a fallas, no se deben eliminar o imputar
Nitración JOAP (Abs/cm)	37	No, Outlier corresponden a fallas, no se deben eliminar o imputar
Fosforado (ppm)	21	Si se deben imputar por los valores de mediana
Cinc (ppm)	20	Si se deben imputar por los valores de mediana
Agua (%)	17	No, Outlier corresponden a fallas, no se deben eliminar o imputar

Finalmente, posterior a este revisión y análisis se procede con la imputación de los datos bajos las reglas de negocios definidas anteriormente, para este proceso se implementa el modelo K-Vecinos en donde se busca imputar los datos a partir de similitud con las otras muestras tal como se plasma en la Parte I: Calidad de datos

Una vez generado unos datos limpios y de acuerdo con los lineamientos del cliente se procede a generar el matriz de correlación




Ilustración 4, Matriz de correlación posterior al tratamiento de datos

A continuación, se describen algunas de las correlaciones interesantes que han sido confirmadas por los analistas expertos de la organización.

1. Metales de desgaste

- Fe–Si (0.39) y Fe–PQ (0.22): Indican desgaste abrasivo y coherencia.
- Zn–Ca (–0.56) y Mg–B/Ca (–0.60): Diferencias entre paquetes de aditivos.
- P–Zn–B (0.45–0.59): Consistencia del sistema de aditivos.
- Pb–Cu (0.25): Desgaste conjunto en cojinetes Pb–Cu.
- Pb–Hollín/Nitración (0.19 / 0.14): Hollín degrada la lubricación y aumenta desgaste.

2. Degradación del lubricante

- Oxidación–Sulfatación (0.93): Redundancia; posible eliminación en modelos.
- Hollín se asocia con viscosidad (0.23): Incrementa degradación del aceite.

3. Contaminación

- Agua sin correlaciones relevantes: No influye en esta población.
- Silicio–Fe/Cu (0.39 / 0.32): Contaminación abrasiva (polvo).
- Dilución Combustible–Viscosidad (–0.21): Disminución esperada de viscosidad.

4. Propiedades del lubricante

- Viscosidad @100°C correlaciona con oxidación y sulfatación (~0.25): Incremento por degradación térmica.

Para un análisis más detallado diríjase al notebook “Exploración de datos.ipynb” en donde encontrara con mayor detalle la explicación de la correlación entre las diferentes variables.

Entendimiento de los datos posterior a la aplicación de técnicas de limpieza




Ilustración 5. Análisis de distribución de variables numéricas posterior al tratamiento de los datos

En la gráfica anterior se presenta la distribución de los datos una vez han sido limpiados y sin faltantes. Algunas observaciones interesantes y que servirán de base para el desarrollo posterior son:

- Algunos elementos indican una distribución bimodal, como lo son el calcio, el magnesio y el molibdeno. Estos elementos hacen parte del paquete de aditivos del aceite de motor. La presencia de este comportamiento indica o que en el rango de tiempo en el que se recolectaron estas muestras hubo un cambio en la formulación del aceite o se debe a fallas reales que implican mezcla de aceite entre compartimentos o sistemas distintos.

- Los elementos metálicos muestran una concentración baja sin embargo se observan algunos valores altos lo que puede ser señal de fallas presentes en el componente.




Ilustración 6, Análisis comparativo de medias de variables numéricas frente a las clases de la variable "Severidad" posterior al tratamiento de datos

- Metales de desgaste (Fe, Cu, Cr, Pb) muestran incremento exponencial exclusivo en clase "Critical", siendo excelentes predictores de condición crítica pero pobres para diferenciar entre Unrated/Normal/Warning
- Parámetros de degradación química (Oxidación, Nitración, Hollín) presentan progresión gradual consistente a través de todas las clases, convirtiéndolos en los mejores candidatos para clasificación multinivel
- Contaminantes (Sodio, Agua, Silicio) exhiben saltos dramáticos únicamente en "Critical", útiles como flags binarios de condición severa, pero con limitado valor para clasificación intermedia
- Aditivos y propiedades físicas (Ca, Zn, P, Mg, Mo, Viscosidad) muestran variación mínima entre clases (<20%), sugiriendo bajo poder discriminante

Desbalance de Clases

La exploración previa identificó un desbalance significativo en la variable objetivo Assigned Condition Rating: la clase Normal concentra aproximadamente el 84.22% de las observaciones, Warning el 12.19% y Critical el 3.6%. Este desbalance fue tratado mediante dos mecanismos:

- SMOTE (Synthetic Minority Over-sampling Technique): aplicado exclusivamente sobre el conjunto de entrenamiento, generando muestras sintéticas interpoladas para las clases minoritarias. El conjunto de prueba se mantuvo sin modificar con la distribución original para reflejar condiciones reales de operación.

Ingeniería de Variables SACODE

Se construyeron cuatro variables categóricas ordinales nuevas mediante la metodología SACODE (Salud, Desgaste, Contaminación y General), siguiendo los principios de la metodología Noria para análisis de aceite. Cada variable toma uno de tres estados: Normal, Advertencia o Crítico. Los límites de clasificación se calcularon estadísticamente (media $\pm k \cdot \sigma$) y fueron ajustados con criterio experto del cliente para los predictores Sodio, Oxidación JOAP, Cobre y Plomo.

Una vez calculadas las calificaciones individuales para cada categoría (Salud, Desgaste, Contaminación), se determina la calificación general de la muestra aplicando el criterio de peor caso, de esta manera la calificación general corresponde al estado más severo registrado entre las tres categorías SACODE para cada muestra.

Un hallazgo relevante fue que los predictores muestran distribuciones significativamente distintas entre flotas. Por esta razón, los límites SACODE se recalcularon de forma independiente para cada flota (con un mínimo de 30 registros para ser considerada), y se entrenaron modelos separados por flota. Este enfoque corresponde a una verificación implícita del supuesto de estacionariedad del proceso dentro de cada grupo operacional. Cabe destacar que este supuesto fue validado debido a que los modelos realizados de manera generalizada entre flotas, el poder predictivo de los modelos no mostraba una buena generalización del problema de clasificación, esto se mostrara a continuación.




Ilustración 7, Distribución de predictores por flota

Una vez aplicado el cálculo de límites por flota se obtienen los siguientes resultados de segregación severidad de la muestra basado en la metodología SACODE

Calificación SACODE por Flota — Metodología Noria




Ilustración 8, Resultados de severidad SACODE por flota

Otro hallazgo relevante durante el análisis descriptivo entre la clasificación otorgada según la metodología de SACODE y la clasificación asignada por los analistas de confiabilidad es la discrepancia en ciertas muestras en donde la clasificación no solo se otorga basado en los criterios de noria, a continuación, se presentan las tablas de contingencias realizadas en donde se evidencia esta discrepancia.

Validación SACODE vs Criterio del Analista — Tablas de Contingencia




Ilustración 9, Tablas de contingencia para contrastar resultados de reglas SACODE vs Criterio del analista

Los heatmaps de contingencia revelan una correlación positiva y consistente entre la severidad calculada mediante la metodología SACODE y el criterio técnico asignado por el analista de confiabilidad cuando el resultado es "Normal".

Sin embargo, el análisis también expone limitaciones importantes del enfoque basado exclusivamente en límites condenatorios estadísticos:

- **SACODE_Salud:** De las 3,547 muestras calificadas como Normal por SACODE, 3,031 coinciden con el criterio del analista (85.5%), sin embargo, se observan 83 muestras clasificadas como Crítico por SACODE que el analista calificó como Normal, lo que sugiere posibles sobreestimaciones del límite estadístico en variables de salud.
- **SACODE_Desgaste:** Presenta el mayor volumen de discrepancia en la clase Crítico (74 muestras SACODE Crítico vs ACR Advertencia), indicando que los metales de desgaste pueden alcanzar los límites condenatorios sin que el analista considere la condición como crítica en el contexto operativo del componente.

- **SACODE_Contaminación:** Muestra el patrón más consistente en Normal (3,359 coincidencias), pero con alta discrepancia en Crítico, donde el **49%** de las muestras clasificadas como Crítico por SACODE reciben calificación Normal por parte del analista.
- **SACODE_General:** El 32% del total (aproximadamente 1,404 muestras) presenta divergencia entre la calificación SACODE y el criterio del analista, siendo la clase Crítico la más afectada con solo un 49.45% de concordancia.

La discrepancia observada no invalida la metodología SACODE, sino que evidencia que la clasificación de severidad en análisis de aceite no puede resolverse únicamente mediante reglas estadísticas de límites condenatorios por predictor.

El analista de confiabilidad incorpora en su diagnóstico elementos contextuales que los límites estadísticos no capturan de forma aislada, tales como:

- Tendencia histórica del componente (incremento gradual vs. pico aislado)
- Horas de servicio acumuladas y proximidad al intervalo de cambio de aceite
- Condición simultánea de múltiples predictores (análisis multivariado implícito)
- Contexto Operacional en donde se encuentran operando los equipos
- Conocimiento del historial de mantenimiento y fallas previas del activo

Esta limitación refuerza la justificación del modelo supervisado de clasificación como etapa siguiente del proyecto: el aprendizaje automático sobre los patrones históricos de decisión del analista permitirá capturar estas relaciones no lineales y contextuales que los límites estadísticos simples no logran modelar, mejorando así la concordancia con el criterio experto y reduciendo la variabilidad diagnóstica.

Preprocesamiento según Tipo de Modelo

Se implementaron dos esquemas de preprocesamiento en función de los requerimientos de cada algoritmo:

- Con escalado (StandardScaler): para Regresión Logística, SVM y MLP, cuyo desempeño es sensible a la magnitud de las variables numéricas.
- Sin escalado (passthrough): para Random Forest, XGBoost y LightGBM, que son invariantes a la escala de las variables.

Las variables categóricas ordinales SACODE fueron codificadas mediante OrdinalEncoder con el orden de severidad [Normal, Advertencia, Crítico] en todos los casos.

Entrenamiento, Validación y Calibración de Modelos de clasificación de modo de falla

Selección de Variables

El conjunto de predictores finales incluye 21 variables numéricas correspondientes a los resultados fisicoquímicos del análisis de aceite (metales de desgaste, aditivos, contaminantes, propiedades físicas medidas en ppm, ABS/cm o %) y 4 variables categóricas ordinales SACODE derivadas (SACODE_Salud, SACODE_Desgaste, SACODE_Contaminacion, SACODE_General). Se

excluyeron las columnas de identificación, las calificaciones de referencia (Assigned Condition Rating, Rule Based Rating, ACR_Homologado) y la variable de flota del espacio de predictores.

Esquema de Entrenamiento y Validación

Se implemento el siguiente esquema de evaluación:

- División train/test: 80% / 20% con estratificación por clase (stratify=y) para preservar las proporciones originales de la variable objetivo en ambos conjuntos.
- Validación cruzada: StratifiedKFold con 5 particiones y shuffle=True sobre el conjunto de entrenamiento balanceado con SMOTE.

Tabla 7, Configuración general de la validación cruzada implementada

Parámetro	Configuración y Justificación
Tipo de CV	StratifiedKFold, preserva la proporción de clases en cada fold
Número de folds	k = 5, balance entre varianza de la estimación y costo computacional
Conjunto de aplicación	Exclusivamente sobre el train balanceado (post-SMOTE)
Normalización	StandardScaler dentro del pipeline para LR, SVM, MLP. Passthrough para RF, XGBoost, LightGBM (invariantes al escalamiento)
Encoding SACODE	OrdinalEncoder con orden explícito: Normal (0) < Advertencia (1) < Crítico (2). Preserva relación ordinal

- Evaluación final: Los modelos entrenados con el conjunto completo de entrenamiento balanceado se evaluaron sobre el conjunto de prueba con la distribución de clases original.

Parametrización de los Modelos

Los hiperparámetros utilizados en el pipeline de entrenamiento global (sobre todos los datos sin segmentar por flota) fueron los siguientes. Los mismos parámetros se aplicaron en los pipelines por flota:

Tabla 8, Hiperparámetros por modelo

Modelo	Hiperparámetros principales
Regresión Logística	max_iter=1000, class_weight='balanced'
Random Forest	n_estimators=400, max_depth=20, class_weight='balanced'
XGBoost	n_estimators=300, max_depth=5, learning_rate=0.05, subsample=0.8, colsample_bytree=0.8
LightGBM	n_estimators=300, max_depth=5, learning_rate=0.05, class_weight='balanced'
SVM	kernel='rbf', C=10, class_weight='balanced', probability=True

MLP

hidden_layer_sizes=(128,64), max_iter=500, early_stopping=True

Métricas de Evaluación y su Justificación

Dado que el problema es de clasificación multiclase con clases desbalanceadas y con asimetría en el costo de los errores, se definieron las siguientes métricas:

- F1-Score Weighted: métrica principal para la validación cruzada. Calcula el F1 de cada clase ponderado por su frecuencia, compensando el efecto del desbalance de clases y resumiendo el balance entre precision y recall.
- Recall de la clase critica: métrica prioritaria en el conjunto de prueba. Cuantifica la proporción de casos realmente críticos que el modelo identifica correctamente. En este contexto, un Falso Negativo (clasificar como Normal un caso Critico) tiene un costo operativo mayor que un Falso Positivo (generar una alerta que el analista valida y descarta). La detección de metales de desgaste elevados (High Wear Metals) o de condición crítica es el requerimiento de mayor valor para el negocio.
- F1-Score de la clase critica: complementa al recall de la clase critica, incorporando la precision para evitar una explosión de falsas alarmas.
- AUC-ROC Weighted (one-vs-rest): métrica de capacidad discriminativa global del modelo sobre las tres clases, independiente del umbral de clasificación.
- Accuracy: métrica de referencia, reportada pero no usada como criterio principal de selección debido al desbalance de clases.

Análisis de Resultados y Selección de Modelos

Resultados del Pipeline Global (todas las flotas)

La primera iteración de pruebas se realizó con los datos de todas las flotas combinados. Los modelos de ensamble basados en arboles de decisión (Random Forest, XGBoost y LightGBM) presentaron el mejor desempeño en F1 Weighted durante la validación cruzada. Sin embargo, al evaluar sobre el conjunto de prueba con la distribución original, el recall de la clase critica bajo drásticamente en todos los modelos. Este hallazgo revelo que el desbalance residual de la clase critica (3.6% del total) no es completamente compensado por SMOTE ni por los pesos de clase cuando se mezclan datos de múltiples flotas con comportamientos fisicoquímicos distintos.

Este hallazgo motivo la estrategia de segmentación por flota: al separar los datos por tipo de maquinaria y recalcular los limites SACODE específicos para cada grupo, se espera que los modelos capturen mejor los patrones de desgaste propios de cada flota y mejoren el recall de la clase critica.




Ilustración 10, Resultados de la primera iteración (Todas las flotas)

En términos generales, los modelos evaluados presentan un buen desempeño discriminativo, con valores de AUC superiores a 0.85 y un F1-Score alto en la mayoría de los casos. No obstante, se identificaron limitaciones relevantes para el modo de falla asociado a altos metales, definido como crítico dentro del proyecto, el Recall no alcanza el umbral mínimo establecido. Por su parte, el modelo de regresión logística registró los resultados más bajos en todas las métricas evaluadas, lo cual era previsible dado que sus supuestos básicos no se cumplen en este contexto; este modelo se incluyó únicamente como referencia comparativa y su comportamiento confirma la complejidad del problema de clasificación abordado.

Las matrices de confusión (Ver notebook “Modelos_Ensamble.ipynb” sección desarrollo de modelos de aprendizaje) y los indicadores de desempeño obtenidos evidencian que los modelos no logran segregar de manera adecuada los ocho modos de falla, lo que sugiere la existencia de comportamientos similares dentro de la misma población de datos que generan clasificaciones ambiguas. Ante esta situación, el área de confiabilidad de la organización planteó que el contexto operativo de cada tipo de flota puede determinar distribuciones y comportamientos distintos en las variables predictoras. Con base en esta recomendación, se tomó la decisión de segmentar los datos por flota y aplicar la metodología de clasificación de SACODE de forma independiente para cada una, aprovechando la distribución propia de sus variables. Adicionalmente, se contempla el uso de SMOTE para balancear los modos de falla al interior de cada flota y mejorar así la capacidad de generalización de los modelos.

NOTA: Se exploró usar PCA para evitar problemas de multicolinealidad y reducir dimensionalidad en el modelo de regresión logística, sin embargo, los resultados obtenidos no lograron superar las métricas obtenidas por regresión logística sin PCA. Ver sección Enfoque PCA Regresión Logística en el notebook “Modelos_Ensamble.ipynb”.

Resultados por Flota

Se entrenaron y evaluaron modelos independientes para Flota_1 y Flota_2 utilizando los límites SACODE calculados específicamente para cada grupo. En ambas flotas se aplicó el mismo conjunto de seis algoritmos y el mismo esquema de validación (5-Fold StratifiedKFold + evaluación en test). La variable objetivo utilizada en los modelos por flota es Fault Effect, que clasifica las muestras en categorías modo de falla relevantes para el mantenimiento. Ver sección Modelo Flota 1 y Modelo Flota 2 en el notebook “Modelos_Ensamble.ipynb”.

NOTA: A partir de los resultados obtenidos en esta etapa se toma la decisión de incluir la flota con un feature del problema de clasificación.

Resultados de enfoque unificado con flota como Feature

En este enfoque se calcularon las categorías de SACODE usando los límites estadísticos propios de cada flota. También se balancearon los conjuntos de flotas por modos de falla. Estos datos fueron luego agregados en un solo set de datos sobre el cual se volvieron a correr los modelos seleccionados obteniendo los siguientes resultados:




Ilustración 11, Resultados del enfoque unificado sobre la muestra de Test

Tabla 9, Resultados luego de Validación cruzada.

Modelo	F1 Weighted (CV)	Std ($\pm$)	Recall W.	Accuracy
LightGBM	0.9942	± 0.0007	0.9942	0.9942
Random Forest	0.9924	± 0.0011	0.9924	0.9924
XGBoost	0.9905	± 0.0010	0.9905	0.9905
MLP	0.9883	± 0.0030	0.9884	0.9884
SVM	0.9717	± 0.0011	0.9723	0.9723
Logistic Regression	0.7778	± 0.0086	0.7763	0.7763

LightGBM presenta la menor varianza (± 0.0007), indicando alta estabilidad entre folds. Regresión Logística muestra la mayor varianza (± 0.0086), coherente con su menor capacidad de capturar relaciones no lineales entre los predictores fisicoquímicos. Los modelos de ensamble presentan F1 > 0.99 con std < 0.003 , confirmando ausencia de sobreajuste severo en el espacio de entrenamiento balanceado.

A continuación, se muestra los resultados de los diferentes modelos para la predicción de los modos de falla.

1. Modo de Falla: No Fault Identified

Modelo	Correctas	% Correcto	Observación
LightGBM	1,250	98.1%	Mínimos falsos positivos, mejor modelo
Random Forest	1,232	96.7%	Muy sólido en clase mayoritaria
XGBoost	1,221	95.8%	53 confundidas con otras clases
MLP	1,170	91.8%	104 mal clasificadas
SVM	1,133	88.9%	141 mal clasificadas, mayor dispersión
Logistic Regression	803	63.0%	471 mal clasificadas, inaceptable en producción

2. Modo de Falla: Abnormal Combustion

Modelo	Recall	Correctas/83	Observación
Random Forest	90.4%	75/83	Mejor detección de Abnormal Combustion
LightGBM	86.7%	72/83	Segunda mejor, 4 confundidas con No Fault
XGBoost	80.7%	67/83	9 confundidas con No Fault, 6 con High Wear Metals
Logistic Regression	67.5%	56/83	11 confundidas con No Fault
SVM	65.1%	54/83	Mayor dispersión: 15 confundidas con High Wear Metals
MLP	59.0%	49/83	Peor detección, 23 confundidas con No Fault

3. Modo de Falla: High Wear Metals (Modo de Falla Crítico)


Modelo	Recall	Correctas/47	Observación
LightGBM	83.0%	39/47	Mayor Recall en esta clase crítica
SVM	80.9%	38/47	Competitivo en esta clase

Random Forest	78.7%	37/47	Estable
MLP	78.7%	37/47	Similar a RF
XGBoost	72.3%	34/47	11 confundidas con No Fault
Logistic Regression	59.6%	28/47	Más confusiones con No Fault

4. Modo de Falla: Fluid Condition Deteriorating

Modelo	Recall	Correctas/34	Observación
Random Forest	85.3%	29/34	Mejor desempeño, empatado con LightGBM
LightGBM	85.3%	29/34	Igual que RF, 5 confundidas con No Fault
XGBoost	76.5%	26/34	8 confundidas con No Fault
SVM	47.1%	16/34	Alta confusión, 15 clasificadas como No Fault
Logistic Regression	47.1%	16/34	Similar a SVM en esta clase
MLP	41.2%	14/34	Mayor número de confusiones, 18 con No Fault

Para complementar el análisis realizado a partir de la matriz de confusión se grafican las curvas ROC comparativa sobre el conjunto de prueba consolidado, este indicador muestra la capacidad discriminativa global de cada modelo, independientemente del umbral de decisión. Un AUC alto garantiza que el modelo tiene capacidad real de distinguir entre clases, aunque el umbral default no sea óptimo.



Modelo	AUC-ROC	Ranking	Interpretación
Random Forest	0.9831	#1	Mejor capacidad discriminativa global
LightGBM	0.9780	#2	Muy competitivo, menor gap vs RF
XGBoost	0.9751	#3	Sólido, mejor F1 Weighted en test
SVM	0.9525	#4	Bueno, gap notable vs ensambles
MLP	0.9286	#5	Aceptable, mayor variabilidad
Logistic Regression	0.8748	#6	Limitado, relaciones lineales insuficientes

Todos los modelos superan $AUC=0.87$, confirmando que el sistema tiene capacidad discriminativa real. El AUC de RF (0.9831) indica que en el 98.3% de los casos el Atrial (Cuerpo) modelo asigna mayor probabilidad a la clase correcta que a una clase incorrecta seleccionada aleatoriamente.

Tabla 10, Resumen de comparación de modelos luego de enfoque unificado

Criterio	LightGBM	XGBoost	RF	SVM	MLP
F1 CV (balanceado)	0.9942 ★	0.9905	0.9924	0.9717	0.9883
F1 Test (real)	0.8414	0.8571 ★	0.8538	0.8185	0.8265
AUC-ROC global	0.9780	0.9751	0.9831 ★	0.9525	0.9286
Estabilidad CV (std)	± 0.0007 ★	± 0.0010	± 0.0011	± 0.0011	± 0.0030
No Fault Recall	98.1% ★	95.8%	96.7%	88.9%	91.8%
Interpretabilidad (SHAP)	Sí ★	Sí ★	Sí	No	No

La selección de LightGBM como modelo definitivo para la clasificación de modos de falla se fundamenta en un análisis multi-criterio que lo posiciona como el modelo más equilibrado entre capacidad predictiva, estabilidad, eficiencia computacional e interpretabilidad:

- **Capacidad discriminativa por clase:** LightGBM supera a XGBoost en 7 de 8 modos de falla en el , con las mayores ventajas en Fuel Entry ($\Delta=0.014$) y Coolant Entry ($\Delta=0.009$). Es el único modelo con $AUC > 0.97$ en 7 clases simultáneamente.
- **Estabilidad en validación cruzada:** Presenta la menor varianza entre todos los modelos evaluados, lo que indica que su desempeño es consistente independientemente de la partición de datos utilizada. Esta propiedad es crítica en un entorno de producción donde los datos de entrada cambian con el tiempo.
- **Control de falsas alarmas:** Al clasificar correctamente el 98.1% de las muestras sin falla, LightGBM minimiza las intervenciones de mantenimiento innecesarias, reduciendo el costo operativo asociado a falsas alertas. Este valor supera al de XGBoost (95.8%) y Random Forest (96.7%).
- **Eficiencia computacional:** LightGBM utiliza un algoritmo de construcción de árboles basado en histogramas que lo hace significativamente más rápido que XGBoost en inferencia, lo cual es relevante dado que el sistema opera en despliegue local sin infraestructura cloud.
- **Interpretabilidad:** Compatible con SHAP TreeExplainer, lo que permite explicar cada predicción individual al analista de confiabilidad, fortaleciendo la confianza y adopción del sistema por parte del equipo técnico.

El notebook “Modelos_Ensamble.ipynb” contiene el código completo de entrenamiento y evaluación incluyendo las matrices de confusión y las comparativas de métricas por modelo.

Ajustes Implementados

Como resultado del análisis de la primera iteración, se implementaron los siguientes ajustes:


- **Segmentación del modelo por flota:** en lugar de un modelo único global, se entrenaron modelos especializados para cada flota, con sus propios límites condenatorios SACODE.
- **Recalculo de límites SACODE por flota:** los histogramas por predictor segmentados por flota confirmaron diferencias significativas en las distribuciones, justificando límites independientes.
- **Ajuste experto de límites:** para Sodio (advertencia: 40 ppm, crítico: 100 ppm), Oxidación JOAP (advertencia: 19 ABS/cm, crítico: 21 ABS/cm), Cobre (advertencia: 6 ppm, crítico: 8 ppm) y Plomo (advertencia: 4 ppm, crítico: 6 ppm), se incorporaron los criterios del cliente sobre los límites estadísticos calculados automáticamente.
- **Ajuste de k_neighbors en SMOTE** para Flota_2 (k=4), dado el menor número de muestras disponibles en esa flota.
- **Exploración de PCA + Regresión Logística** como alternativa de reducción de dimensionalidad, incluyendo la selección del número óptimo de componentes basada en la varianza acumulada explicada.

Los criterios que guiarán la evaluación final del prototipo son: recall de la clase crítica superior a 0.70, F1-Score Weighted superior a 0.70 en el conjunto de prueba, y AUC-ROC superior a 0.85, todo ello evaluado sobre datos con la distribución de clases real (sin balanceo artificial).

Desarrollo de modelo de clasificación de severidad

Se probaron 2 enfoques para el desarrollo de este modelo:

- Sin balanceo de clases y Feature “Fault Effect” como predictor



En el proceso de asignación de severidad de la condición, el modo de falla identificado en la muestra constituye un insumo determinante para el analista de confiabilidad. Esta variable no solo orienta la clasificación del nivel de severidad (Normal, Advertencia, Crítico) sino que define directamente la prioridad de atención del activo, dado que distintos modos de falla implican diferentes velocidades de deterioro y potenciales consecuencias operativas.

Por esta razón, y con el objetivo de replicar fielmente la lógica de decisión del analista experto, el modo de falla fue incorporado como una feature adicional en el proceso de clasificación supervisada.

Su inclusión busca enriquecer la capacidad discriminativa de los modelos al introducir información cualitativa del diagnóstico que complementa las variables fisicoquímicas numéricas.


Respecto al tratamiento de esta variable, se tomó la decisión técnica de no aplicar balanceo de clases (SMOTE) sobre el modo de falla. Esta decisión se fundamenta en que, a diferencia de las variables numéricas donde SMOTE genera muestras sintéticas mediante interpolación entre vecinos cercanos en el espacio de features, el modo de falla es una variable categórica que representa una condición real diagnosticada por un analista

Los seis modelos evaluados muestran un desempeño general aceptable en F1 Weighted (todos por encima de 0.80) y AUC-ROC (todos por encima de 0.85), con LightGBM y XGBoost liderando en la primera métrica y XGBoost junto a Random Forest en la segunda.

Sin embargo, el Recall Crítico, la métrica más importante desde la perspectiva de negocio, es insuficiente en todos los modelos, sin que ninguno supere el valor de 0.65. Este resultado era previsible dado que en esta corrida no se aplicó balanceo de clases detrimento de la detección de casos críticos.

Para la siguiente iteración se prevé incorporar SMOTE para balancear las clases y mejorar la sensibilidad sobre los eventos de mayor severidad. Adicionalmente, deberá verificarse la disponibilidad del feature Fault Effect en el flujo de producción, dado que su ausencia en tiempo real comprometería la viabilidad del modelo desplegado.

- Con balanceo de clases sin incluir "Fault Effect" como predictor



Los modelos mantienen un AUC-ROC aceptable (todos por encima de 0.82), liderado por Random Forest y XGBoost, lo que indica que la capacidad de clasificación global se preserva. Sin embargo, el F1 Weighted muestra una caída respecto a la corrida anterior, con MLP (0.741) y Regresión Logística (0.667) rezagándose notablemente, lo que puede atribuirse al efecto del balanceo sobre la distribución de predicciones en clases mayoritarias.

El Recall Crítico, a pesar de haberse aplicado SMOTE, sigue siendo insuficiente: ningún modelo supera 0.39, con XGBoost y LightGBM como los mejores (0.387). Comparado con la corrida anterior, que incluía Fault Effect sin balanceo y alcanzaba valores de hasta 0.645, el resultado es considerablemente más bajo, lo que refuerza la hipótesis de que el feature Fault Effect era el principal impulsor de la detección de la clase crítica, más que el desbalance de clases en sí mismo.

En conjunto, estos resultados sugieren que el balanceo con SMOTE por sí solo no es suficiente para mejorar el Recall Crítico cuando se carece de predictores informativos para esa clase. La siguiente iteración debería evaluar la combinación de SMOTE con el feature Fault Effect, analizando en paralelo su disponibilidad real en el flujo de producción.

Componentes Pendientes y Plan de Implementación

Componentes Pendientes de Implementación

Con base en el estado actual del prototipo, se identifican los siguientes componentes que aún no han sido implementados:

- **Optimización de hiperparámetros:** los parámetros actuales de los modelos fueron definidos con criterio experto, pero no se ha realizado búsqueda sistemática (GridSearchCV o RandomizedSearchCV) para identificar la combinación óptima de hiperparámetros, especialmente para maximizar el recall de la clase crítica.
- **Ajuste de umbral de clasificación:** actualmente se usa el umbral por defecto (0.5). Un ajuste del umbral de decisión podría mejorar el recall de la clase crítica a costa de un incremento moderado de falsas alarmas, lo cual es aceptable según el contexto del negocio.
- **Serialización de modelos:** los modelos entrenados no han sido exportados (pickle, joblib o WHL) para su despliegue en producción. Este paso es necesario para el prototipo funcional.
- **Interfaz de usuario o tablero de resultados:** no existe aún una interfaz que permita a los analistas ingresar o cargar resultados de análisis de aceite y obtener la clasificación automática.
- **Generación automatizada de reportes:** el sistema actual genera salidas en el entorno de Jupyter, pero no produce reportes en formato estándar (PDF, Word, Excel) para los analistas o el equipo de mantenimiento.
- **Pipeline de inferencia en producción:** no se ha implementado aun el flujo completo de preprocesamiento, cálculo SACODE y predicción que se ejecutaría automáticamente sobre nuevos registros de laboratorio.
- **Validación con usuarios finales (analistas):** los modelos no han sido sometidos a una prueba de aceptación con los analistas del sitio que permita verificar la coherencia de las clasificaciones automáticas con el juicio experto.
- **Monitoreo de datos y modelo en producción:** una vez desplegado el sistema, se requiere implementar un esquema de monitoreo continuo que permita detectar degradación en el desempeño del modelo, cambios en la distribución de los datos de entrada (data drift) y desviaciones en las predicciones respecto al comportamiento esperado. Este componente es fundamental para garantizar la confiabilidad del sistema a largo plazo y determinar cuándo es necesario reentrenar o ajustar los modelos.
- **Evaluación combinada de SMOTE y feature Fault Effect en el modelo de clasificación de severidad:** los resultados obtenidos indican que ninguna de estas dos estrategias por separado es suficiente para alcanzar un Recall Crítico adecuado. Como próximo paso se deberá ejecutar una corrida que combine el balanceo de clases con SMOTE y la inclusión del feature *Fault Effect*, evaluando en paralelo su disponibilidad real en el flujo de producción para determinar la viabilidad del modelo en despliegue.

Plan de Implementación del Prototipo Funcional

Tabla 11, Planificación de actividades futuras

Actividad	Responsable	Prioridad
-----------	-------------	-----------

Optimización de hiperparámetros y ajuste de umbral de clasificación para maximizar recall critico	Daniel Martínez	Alta
Serialización y versionado de modelos seleccionados por flota	Daniel Martínez	Alta
Desarrollo del pipeline de inferencia en producción (carga de datos, SACODE, predicción)	Daniel Martínez	Alta
Desarrollo de interfaz de usuario o tablero	Luis Miguel Ortega	Media
Generación automática de reportes para analistas y equipo de mantenimiento	Luis Miguel Ortega	Media
Sesión de validación con analistas del sitio (prueba de aceptación)	Luis Miguel Ortega + Cliente	Alta
Preparación de entregables y presentación ejecutiva del prototipo	Daniel Martínez + Luis Miguel Ortega	Alta
Monitoreo de datos y modelo en producción	Luis Miguel Ortega	Alta
Evaluación combinada de SMOTE y feature Fault Effect en el modelo de clasificación de severidad	Daniel Martínez	Alta

Las actividades de alta prioridad deben completarse antes de la evaluación del prototipo con el cliente. Las de prioridad media pueden desarrollarse en paralelo o inmediatamente después de la sesión de validación con analistas, dependiendo de la disponibilidad del equipo.

Definición de reglas para la prescripción de acciones de mantenimiento

A continuación se muestra la tabla consolidada la construcción de reglas basadas en la clasificación de los modos de falla (Fault Effect) y criticidad detectada para generación de recomendaciones básicas de atención.

Tabla 12, Acciones recomendadas para cada combinación de criterios de modos de falla y criticidad

Modo de falla	Warning	Critical
Fuel Entry	- Verificar tendencia histórica de dilución - Revisar consumo de combustible vs horas - Inspección visual de humo (blanco/negro) - Validar estado de inyectores vía escáner o pruebas básicas - Revisar presión de riel / bomba de inyección - Programar prueba de inyectores en banco	- Detener operación si dilución es alta (>5–7%) - Cambio inmediato de aceite y filtro- Prueba completa de inyectores (fugas, pulverización) - Inspección de bomba de inyección - Verificación de sincronización de inyección - Desarme parcial para inspección de cilindros con boroscopio

Dust Entry	- Revisar indicador de restricción de filtro de aire - Inspección visual de filtro de aire - Verificar sellos y abrazaderas en admisión - Revisar estado de mangueras de admisión - Inspeccionar carcasa de filtro - Validar procedimientos de cambio de filtro	- Cambio inmediato de aceite y filtros - Reemplazo completo de filtros de aire - Inspección detallada de sistema de admisión (fugas) - Prueba de hermeticidad del sistema - Inspección interna de cilindros (desgaste abrasivo)
Fluid Condition Deteriorating	- Revisar horas de uso del aceite - Comparar con intervalos de mantenimiento - Verificar temperatura de operación - Revisar historial de cambios de aceite - Evaluar contaminación cruzada - Ajustar frecuencia de monitoreo	- Cambio inmediato de aceite y filtros - Análisis complementarios (TBN, TAN, oxidación) - Identificar fuente de degradación (temperatura, contaminación) - Inspección del sistema de enfriamiento - Revisión de cargas operativas - Ajuste de estrategia de lubricación
Abnormal Combustion	- Verificar códigos de falla (ECM) - Inspección de humo y comportamiento del motor - Revisar calidad del combustible - Validar calibración básica del motor - Inspección preliminar de inyectores - Revisar sistema de admisión/escape	- Detener operación si hay riesgo de daño - Diagnóstico completo de inyección - Inspección de pistones y válvulas - Prueba de compresión - Verificación de sincronización - Cambio del componente
Coolant Entry	- Verificar nivel de refrigerante - Inspección visual de emulsión en aceite - Revisar historial de consumo de coolant - Prueba de presión del sistema de enfriamiento - Análisis de glicol en aceite - Monitoreo frecuente	- Parada inmediata del equipo - Cambio de aceite y flushing del sistema - Prueba de fugas (radiador, enfriador, culata) - Inspección de enfriador de aceite - Revisión de junta de culata - Cambio del componente
High Wear Metals	- Analizar tendencia vs muestras anteriores - Identificar tipo de metal (Fe, Cu, Pb, etc.) - Correlacionar con horas y condiciones de operación - Revisar calidad del aceite - Verificar condiciones de carga - Programar inspección dirigida	- Inspección inmediata del componente asociado - Análisis de partículas (ferrografía) - Desarme parcial del motor - Reemplazo de componentes desgastados - Evaluación de causa raíz (lubricación, contaminación) - Cambio del componente
Questionable Sample Results	- Verificar procedimiento de muestreo - Revisar punto de toma de muestra - Validar etiquetado y trazabilidad - Repetir muestreo - Comparar con tendencias previas - Confirmar resultados con laboratorio	- Re-muestreo inmediato - Suspender decisiones hasta confirmar datos - Auditoría del proceso de muestreo - Validación cruzada con otro laboratorio - Inspección básica del equipo (por precaución) - Repetir análisis completo

Referencias

- Jardine, A., Lin, D., & Banjevic, D. (2005). A review on machinery diagnostics and prognostics implementing condition-based maintenance. *Elsevier Ltd*, 28.
- Keartland, S., & Van Zyl, T. (2020). Automating predictive maintenance using oil. *IEEE Xplore*, 6.
- Rao, X., Sheng, C., & Guo, Z. (2021). A review of online condition monitoring and maintenance strategy for cylinder liner-piston rings of diesel engines. *Elsevier Ltd*, 23.
- Shah, R., Jaramillo, R., Thomas, G., Rayhan, T., Hossain, N., Kchaou, M., . . . Rosenkranz, A. (2025). Artificial Intelligence and Machine Learning in Tribology: Selected Case Studies and Overall Potential. *ADVANCED SCIENCE NEWS*, 15.
- Tian, Z. (2009). An artificial neural network method for remaining useful life prediction of equipment subject to condition monitoring. *Springer Science+Business Media*, 11.
- Wakirua, J., Pintelona, L., Muchiri, P., & Chemweno, P. (2018). A review on lubricant condition monitoring information analysis for maintenance decision support. *Elsevier Ltd.*, 25.

Nota de Confidencialidad

Este documento contiene información interna de carácter confidencial. Su contenido, incluyendo datos, resultados y análisis, es exclusivo para uso autorizado dentro de la organización. Se prohíbe su reproducción o divulgación sin permiso previo y por escrito de los autores y/o la entidad propietaria de la información.

© 2026. Todos los derechos reservados. Uso exclusivo académico e interno.