

PROYECTO – MANUAL DE USUARIO SISTEMA OILSENSE ML. DASHBOARD DE SALUD DE MOTORES DIESEL

Ing. Daniel Arturo Martínez Morales

Aspirante a título de maestría MIAD, Universidad de los Andes

Ing. Luis Miguel Ortega Cañate

Aspirante a título de maestría MIAD, Universidad de los Andes

Nota de Confidencialidad

El presente documento contiene información técnica, operativa y analítica basada en datos internos suministrados por la organización colaboradora. Dichos datos, así como los resultados, modelos, hallazgos y conclusiones aquí desarrollados, son estrictamente confidenciales y han sido utilizados únicamente con fines académicos y de análisis interno del proyecto.

Queda prohibida la reproducción, divulgación, distribución o uso parcial o total de la información contenida en este documento sin la autorización previa y por escrito de la organización propietaria de los datos. Cualquier uso no autorizado podrá constituir una infracción a las políticas internas de la empresa y a la normativa aplicable en materia de manejo de información sensible.

El contenido de este informe no debe ser interpretado como una publicación oficial ni como un documento destinado a circulación externa.

1. Introducción

OilSense ML es un sistema de clasificación automática de resultados de análisis de aceite usado en motores de maquinaria pesada de la industria minera. El presente manual describe cómo interactuar con el tablero de visualización desarrollado en Power BI, cómo interpretar cada elemento y cómo actuar sobre las recomendaciones generadas por el modelo de Machine Learning.

1.1 Objetivo del sistema

OilSense ML automatiza el proceso de interpretación de análisis de aceite, reduciendo el tiempo de diagnóstico de 36 horas a menos de 10 minutos. El sistema clasifica cada muestra en tres niveles de severidad y predice el modo de falla asociado, permitiendo al equipo de mantenimiento priorizar intervenciones antes de que ocurran fallas catastróficas.

1.2 Audiencia

Perfil	Frecuencia de uso	Foco principal
Analista de Confiabilidad	Diaria / por lote de muestras	Historial, tendencias, impacto de variables, diagnóstico detallado
Gerente de Gestión de Activos	Semanal / reuniones de control	KPIs de resumen, modos de falla, costos evitados

1.3 Sistema de colores semántico

El tablero usa un sistema de colores consistente en todos sus elementos. Familiarizarse con él permite leer la información de un vistazo:

Color	Severidad	Significado operativo
Crítico	Critical	El motor requiere atención inmediata. Riesgo de falla catastrófica. Intervenir antes de la próxima operación.
Advertencia	Warning	Tendencia preocupante detectada. Programar inspección en el corto plazo. Aumentar frecuencia de muestreo.
Normal	Normal	El motor opera dentro de parámetros aceptables. Continuar con el plan de monitoreo estándar.

2. Estructura del Tablero

El tablero está organizado en cinco zonas funcionales. Conocer la ubicación de cada zona acelera el flujo de análisis.



Nota: La imagen anterior es una representación esquemática del tablero implementado.

Zona	Nombre	Contenido
A — Superior	Barra de KPIs	Indicadores ejecutivos: equipos monitoreados, muestras críticas, costos
B — Izquierda	Panel de filtros + Mapa de equipos	Filtros de flota, Asset ID, fecha y edad del componente. Grilla visual de estado por equipo
C — Centro superior	Análisis de aceite histórico + Recomendaciones	Tabla detallada de muestras y tabla de últimas predicciones por equipo
D — Centro inferior	Tendencias SACODE	Tres gráficos de línea: Contaminantes, Desgaste, Salud del aceite

Zona	Nombre	Contenido
E — Derecha	Modos de falla + Impacto de variables	Distribución de modos de falla por severidad y gráficas SHAP de explicabilidad

3. Panel de Filtros (Zona B)

Los filtros del panel izquierdo controlan toda la información desplegada en el tablero. Aplicarlos correctamente es el primer paso en cualquier análisis.

3.1 Filtros disponibles

Filtro de Flota

Selecciona una flota específica o deja en "Todas" para ver el consolidado de la operación. Cada flota tiene sus propios límites condenatorios SACODE calculados estadísticamente, por lo que el modelo aplica criterios diferenciados por tipo de equipo.

Ejemplo: Seleccionar "Flota_1" muestra únicamente los 41 equipos de esa flota con sus límites específicos. Los límites de Boro de Flota_1 difieren de Flota_3 porque las condiciones operativas son distintas.

Filtro de Asset ID

Permite enfocarse en un equipo individual. Una vez seleccionado un Asset ID, todos los gráficos y tablas se actualizan para mostrar exclusivamente el historial de ese motor.

Uso típico del analista: Al recibir una alerta crítica, seleccionar el Asset ID del equipo reportado para ver su historial completo y la explicación SHAP de la muestra más reciente.

Filtro de Observation Date

Define el rango temporal del análisis mediante un control deslizante. El rango disponible va desde septiembre 2024 hasta enero 2025 en el dataset actual. Se puede ajustar manualmente ingresando fechas en los campos.

Filtro de Component Age

Filtra muestras según la edad acumulada del componente (en horas). Útil para comparar el comportamiento del aceite en distintas etapas del ciclo de vida del motor.

3.2 Mapa visual de equipos (Salud de Motores por Equipo)

Debajo de los filtros se encuentra una grilla con el identificador de cada equipo de la flota. El color de fondo de cada celda indica la última severidad predicha:

- Fondo rojo: el equipo tiene la ultima muestra reciente clasificada como Critical.
- Fondo ámbar: el equipo tiene la última muestra clasificadas como Warning.
- Fondo verde : el equipo está en condición Normal.

4. Barra de KPIs (Zona A)

La fila superior del tablero presenta seis indicadores clave de gestión. Están diseñados para la revisión ejecutiva rápida sin necesidad de profundizar en los datos.

KPI	Valor ejemplo	Interpretación
Componentes Monitoreados	41	Total de motores activos en el sistema con al menos una muestra en el período seleccionado.
Motores en Condición Crítico	3	Equipos con la última muestra clasificada como Critical. Requieren intervención inmediata.
Motores en Condición Advertencia	3	Equipos con última muestra en Warning. Requieren seguimiento y aumento de frecuencia de muestreo.
Promedio de Vida de Motores	10.28 mil h	Edad promedio acumulada (horas) de los componentes monitoreados en el período filtrado.
Costo de Componentes en Advertencia (USD)	341.02 mil	Valor estimado de los componentes en estado Warning. Representa el costo en riesgo si no se interviene.
Costo de Componentes en Crítico (USD)	953.67 mil	Valor estimado de los componentes en estado Critical. Es el costo de falla evitado si se actúa a tiempo.

Nota: Los costos son estimaciones basadas en el valor de reposición del componente. No incluyen costos de parada operativa ni mano de obra. Sirven como referencia de prioridad económica.

5. Análisis de Aceite Histórico (Zona C)

La tabla central muestra el detalle de cada muestra procesada por el modelo. Es la fuente principal de información para el analista de confiabilidad durante su revisión diaria.

5.1 Columnas de la tabla

Columna	Descripción
Asset ID	Identificador único del equipo (motor diesel). Ej: Asset_ID_11.
Observation Date	Fecha en que se tomó la muestra de aceite en campo.
Component Age	Edad acumulada del componente en horas al momento de la muestra.
Fault_Effect_Predicho	Modo de falla clasificado por OilSense ML. Valores posibles: No Fault Identified, Abnormal Combustion, Dust Entry, Coolant Entry, Fuel Entry, High Wear Metals, Fluid Condition, Questionable Sample.
Severidad_Predicha	Nivel de severidad: Normal, Warning o Critical.
Aluminio / Cromo / Hierro / Plomo / Cobre (ppm)	Concentración de metales de desgaste en partes por millón. Valores altos indican desgaste interno.
Hollín JOAP (Abs/cm)	Nivel de hollín en el aceite. Valores elevados indican combustión anormal.
Silicio / Sodio / Dilución de Combustible / Aluminio (ppm)	Concentración de elementos contaminantes en partes por millón. Valores altos indican alta contaminación del aceite.
Oxidación/Nitración/Sulfatación JOAP (Abs/cm)	Indicadores de salud del lubricante en JOAP (Abs/cm). Valores altos indican alta degradación del aceite.

5.2 Cómo usar la tabla

1. Ordenar por Severidad_Predicha para ver primero los equipos críticos.
2. Filtrar por Asset ID específico para ver el historial completo de un equipo.
3. Revisar la tendencia de metales de desgaste.

5.3 Tabla de Recomendaciones

A la derecha de la tabla histórica se encuentra la Tabla de Recomendaciones, que muestra la última predicción por equipo. Es la vista más actualizada del estado de la flota y el punto de partida para la planificación del mantenimiento.

Flujo recomendado: Revisar primero la Tabla de Recomendaciones para identificar equipos en Critical o Warning. Luego hacer clic en el Asset ID para filtrar el tablero y ver el detalle histórico completo de ese equipo.

6. Análisis de Tendencia SACODE (Zona D)

La metodología SACODE (Salud — Contaminación — Desgaste) organiza los parámetros del aceite en tres categorías diagnósticas. Los tres gráficos de línea en la parte inferior central del tablero muestran la evolución de cada predictor.

6.1 Tendencia de Contaminantes

Muestra la evolución de: Hollín JOAP (Abs/cm), Silicio (ppm), Aluminio (ppm) y Sodio (ppm).

Parámetro	Modo de falla asociado	Qué observar
Hollín JOAP	Abnormal Combustion	Valores > 19 Abs/cm: advertencia. > 21: crítico. Tendencia creciente sostenida indica problema de inyección.
Silicio (ppm)	Dust Entry	Incremento brusco indica ingreso de polvo al sistema. Revisar filtros de aire y sellos.
Aluminio (ppm)	Dust Entry	Acompaña al Silicio en contaminación por tierra. Revisar en conjunto.
Sodio (ppm)	Coolant Entry	Sodio > 40: advertencia. > 100: crítico. Indica posible ingreso de refrigerante al aceite.

6.2 Tendencia de Desgaste

Muestra la evolución de: Hierro (ppm), Cobre (ppm), Plomo (ppm) y Cromo (ppm).

Metal	Origen del desgaste	Qué observar
Hierro (ppm)	Camisas, cigüeñal, árbol de levas	El indicador de desgaste más sensible. Incremento > 3 ppm entre muestras = señal de alerta temprana.
Plomo (ppm)	Cojinetes de biela y bancada	Plomo > 4: advertencia. > 6: crítico. Tendencia al alza indica desgaste de cojinetes.
Cobre (ppm)	Bujes, enfriadores de aceite	Cobre > 6: advertencia. > 8: crítico. Puede indicar corrosión en el sistema de enfriamiento.
Cromo (ppm)	Aros de pistón, válvulas	Incremento sostenido indica desgaste de aros. Evaluar junto con hollín y dilución.

6.3 Tendencia de Salud del Aceite

Muestra la evolución de: Oxidación JOAP (Abs/cm), Sulfatación JOAP (Abs/cm), Nitración JOAP (Abs/cm), Molibdeno (ppm) y Cinc (ppm).

Oxidación, Sulfatación y Nitración miden la degradación química del aceite base. Valores crecientes indican que el aceite está llegando al final de su vida útil. Molibdeno y Cinc son aditivos del paquete lubricante: su disminución indica agotamiento del aceite.

Lectura combinada: Si Oxidación sube al mismo tiempo que Cinc y Molibdeno bajan, el aceite está agotado. La acción correcta es programar cambio de aceite, no necesariamente reparación mecánica.

6.4 Evolución de Severidad de las Muestras

El gráfico de barras apiladas muestra cómo se distribuyó la severidad de las muestras por año. Permite identificar si la proporción de muestras críticas está aumentando o disminuyendo en el tiempo.

7. Modos de Falla Según Severidad (Zona E)

El gráfico de barras horizontales en el panel derecho superior muestra la distribución de los modos de falla detectados, desglosados por severidad (Warning, Normal, Critical).

7.1 Modos de falla del sistema

Modo de falla	Categoría SACODE	Descripción y acción sugerida
No Fault Identified	Normal	El modelo no detecta anomalías. Continuar monitoreo estándar.
Abnormal Combustion	Contaminación	Combustión incompleta. Revisar inyectores, sistema de admisión y filtros de aire.
Dust Entry	Contaminación	Ingreso de polvo al sistema. Inspeccionar filtros de aire y sellos de admisión.
Coolant Entry	Contaminación	Ingreso de refrigerante al aceite. Revisar juntas de culata y radiador. Alta urgencia.
Fuel Entry	Contaminación	Dilución del aceite con combustible. Revisar inyectores y anillos de pistón.
High Wear Metals	Desgaste	Concentración elevada de metales. Inspeccionar componentes móviles internos.
Fluid Condition	Salud	Aceite químicamente degradado. Programar cambio de aceite.
Questionable Sample	N/A	La muestra puede tener problemas de toma o contaminación externa. Repetir muestreo.

7.2 Distribución de muestras según severidad

El gráfico de dona muestra el porcentaje de muestras por nivel de severidad en el período seleccionado. En el dataset actual: Normal 86.03%, Warning 6.98%, Critical ~7%. Este gráfico cambia al aplicar filtros de flota o equipo.

8. Análisis de Impacto de Variables — SHAP (Zona E)

La sección de Impacto de Variables es el componente más avanzado del tablero. Utiliza valores SHAP (Shapley Additive explanations) para explicar por qué el modelo de Machine Learning clasificó una muestra específica con determinada severidad.

8.1 Qué es un valor SHAP

SHAP es una técnica de inteligencia artificial interpretable que descompone la predicción del modelo en contribuciones individuales de cada variable. Para cada muestra, el gráfico muestra:

- Las barras rojas (positivas): variables que empujan hacia la clase analizada (Critical o Warning).
- Las barras azules (negativas): variables que reducen la probabilidad de esa clase.

8.2 Cómo leer el grafico de cascada

La gráfica de cascada muestra la explicación de una muestra individual. Se lee de abajo hacia arriba:

1. Cada barra representa el empuje de una variable: rojo sube la probabilidad, azul la baja.
2. El valor del lado izquierdo de cada barra es el valor real de esa variable en esa muestra.
3. El número dentro de la barra es el SHAP value: cuánto subió o bajó la probabilidad.

Ejemplo de lectura: "Hierro (ppm) = 10.68 | +0.11" significa que en esta muestra el Hierro vale 10.68 ppm y empujó la probabilidad de Critical hacia arriba en 0.11 (11 puntos porcentuales). Es la variable que más contribuyó al diagnóstico.

8.3 Gráficas de Explicación disponibles

El tablero muestra dos gráficas SHAP simultáneas para el equipo seleccionado:

Gráfica	Qué muestra y cuándo usarla
Explicación SHAP — Warning	Gráfico de cascada de la muestra con mayor probabilidad de Warning. Usar para entender qué parámetros están generando la advertencia y cuáles son los límites que se acercan a zona de riesgo.
Explicación SHAP — Critical	Gráfico de cascada de la muestra con mayor probabilidad de Critical. Usar para priorizar la intervención y comunicar al equipo de mantenimiento qué componente está fallando y por qué.
SHAP Valores — Clase Critical (Summary)	Vista global de importancia de variables sobre todas las muestras. Las variables más arriba son las que el modelo considera más relevantes globalmente para detectar condiciones críticas en la flota.

9. Limitaciones.

Dentro de las limitaciones identificadas en el desarrollo de los modelos predictivos tenemos:

1. Alcance del modelo restringido a tres flotas específicas

El modelo de clasificación fue entrenado exclusivamente con datos históricos de Flota_1, Flota_2 y Flota_3, cuyas condiciones operativas, tipos de lubricante y ciclos de mantenimiento son particulares de esta operación minera. Los límites condenatorios SACODE, los patrones de desgaste aprendidos y los umbrales de decisión están calibrados para estos equipos específicamente.

Implicación práctica: Aplicar el sistema a flotas con diferente tipo de motor, condiciones ambientales distintas o lubricantes de otra especificación producirá predicciones no confiables sin un proceso de reentrenamiento y validación. El modelo no debe considerarse transferible a otras operaciones sin una fase de adaptación que incluya recolección de datos representativos de la nueva flota.

2. Restricción de despliegue local por acuerdo de confidencialidad

El sistema opera en un entorno 100% local sin conexión a servicios de nube, como resultado de un acuerdo de confidencialidad con el cliente que prohíbe el almacenamiento o procesamiento de datos operacionales en servidores externos. Esta restricción impacta directamente la arquitectura técnica del sistema y sus capacidades de automatización.

Implicación práctica: La actualización del modelo con nuevas muestras es un proceso manual que requiere intervención del equipo técnico. No existe sincronización automática de datos, alertas en tiempo real ni acceso remoto al dashboard desde dispositivos móviles o ubicaciones fuera de la red corporativa.

3. Recall de clase Critical inferior al umbral objetivo del 80%

La métrica de Recall para la clase Critical en el modelo de clasificación de severidad alcanzó valores entre 0.77 con el umbral de decisión por defecto (0.5), por debajo del objetivo de negocio del 80% establecido en la carta del proyecto.

4. Dependencia de la calidad de los datos de entrada

El sistema hereda directamente la calidad de los datos provenientes del laboratorio de análisis de aceite y del ERP corporativo. Durante la fase de exploración de datos se identificaron inconsistencias que afectan la confiabilidad del modelo si no son tratadas antes de la inferencia.

5. Validación técnica con expertos de dominio pendiente

El modelo fue entrenado y evaluado con métricas estadísticas estándar sobre datos históricos. Sin embargo, la validación con analistas de confiabilidad expertos en el dominio, que verifiquen que las predicciones son coherentes con el conocimiento técnico del equipo

10. Flujos de Trabajo Recomendados

10.1 Flujo del Analista de Confiabilidad (uso diario)

1. Abrir el tablero y verificar los KPIs superiores: ¿Cuántos equipos en Critical? ¿Cuántos en Warning?
2. Revisar la Tabla de Recomendaciones (Zona C derecha) para identificar Asset IDs con alerta activa.
3. Hacer clic en el equipo de mayor prioridad en la grilla de Salud de Motores (Zona B).
4. Revisar la tendencia de Desgaste (Zona D) del equipo seleccionado: ¿Hierro, Plomo o Cobre muestran tendencia creciente?
5. Consultar la Tabla de Análisis Histórico para verificar el historial de muestras y confirmar el patrón.
6. Leer la gráfica de cascada SHAP (Zona E) para identificar las variables que más contribuyeron a la clasificación.
7. Registrar la acción correctiva en el ERP y actualizar la tabla de seguimiento.

10.2 Flujo del Gerente de Gestión de Activos (uso semanal)

1. Verificar KPIs: costo total en riesgo (Advertencia + Crítico) y número de equipos por nivel.
2. Revisar la Distribución de Modos de Falla para identificar si hay un tipo dominante en la flota.
3. Analizar la Evolución de Severidad (¿está subiendo o bajando la proporción de críticos?).
4. Tomar decisiones de planificación: frecuencia de muestreo, paradas programadas, presupuesto de mantenimiento.

11. Preguntas Frecuentes

¿Por qué un equipo aparece como Critical si los metales de desgaste parecen normales?

El modelo considera múltiples variables simultáneamente. Una muestra puede ser clasificada como Critical por la combinación de Hollín elevado, SACODE_General crítico y Oxidación alta, aunque los metales individuales no superen el límite. Consultar el Waterfall Plot SHAP para ver qué variables generaron el diagnóstico.

¿Qué significa "Questionable Sample"?

El modelo detectó que los valores de esa muestra son inconsistentes con el historial del equipo o con los patrones típicos de la flota. Las causas más comunes son errores en la toma de muestra, contaminación del frasco, o ingreso de datos incorrectos. Se recomienda repetir el muestreo antes de tomar decisiones de mantenimiento.

¿Cuál es la diferencia entre la Tabla Histórica y la Tabla de Recomendaciones?

La Tabla Histórica muestra TODAS las muestras del período filtrado. La Tabla de Recomendaciones muestra únicamente la ULTIMA predicción por equipo, independientemente de la fecha. Es la vista del estado actual de la flota.

¿El SHAP plot siempre muestra la muestra más crítica?

Por defecto sí: el script selecciona automáticamente la muestra con mayor probabilidad de la clase analizada (Critical o Warning). Al filtrar el tablero por Asset ID específico, el SHAP plot se actualiza para mostrar la muestra más relevante de ese equipo.

¿Con qué frecuencia se actualiza el tablero?

El tablero se actualiza cuando se ejecuta el script de producción con nuevas muestras. El proceso genera el archivo `dataset_final_con_prediccion.xlsx` que alimenta Power BI. La actualización es manual en la versión actual del sistema.

¿Qué hago si el gráfico SHAP no carga o aparece error?

El visual de Python en Power BI requiere que el entorno de Python esté correctamente configurado con las librerías `shap`, `joblib`, `scikit-learn` y `matplotlib`. Verificar que la ruta a los modelos empaquetados (`pipeline_randomforest_calibrado.pkl`) sea accesible desde el equipo donde corre Power BI.

12. Glosario Técnico

Término	Definición
SACODE	Metodología de clasificación del aceite en tres categorías: Salud, Contaminación y Desgaste. Basada en límites condenatorios estadísticos ($\pm 2\sigma$ y $\pm 3\sigma$) calculados por flota.
Límite condenatorio	Umbral estadístico que separa condición Normal de Advertencia ($\pm 2\sigma$) o Crítico ($\pm 3\sigma$). Calculado a partir del historial de la flota específica.
Fault Effect	Modo de falla predicho por el modelo de Machine Learning. Indica el mecanismo de deterioro predominante en la muestra.
Severidad predicha	Nivel de urgencia asignado por el modelo de severidad (Random Forest): Normal, Warning o Critical.
SHAP value	Valor SHAP: contribución individual de una variable a la predicción del modelo. Un valor positivo empuja hacia la clase analizada; negativo la aleja.
Waterfall Plot	Gráfica de cascada SHAP que explica la predicción de una muestra individual, mostrando el aporte de cada variable.
P(Critical)	Probabilidad de que el modelo clasifique una muestra como Critical. Valor entre 0 y 1.
Component Age	Edad acumulada del componente en horas de operación al momento de la toma de muestra.
ppm	Partes por millón. Unidad de concentración usada para metales de desgaste y contaminantes.
JOAP (Abs/cm)	Unidad de medida para parámetros de oxidación, nitración, sulfatación y hollín del aceite mediante espectroscopía infrarroja.
Random Forest	Modelo de Machine Learning basado en múltiples árboles de decisión. Usado en OilSense para clasificar la severidad de las muestras.
LightGBM	Modelo de Machine Learning de gradient boosting. Usado en OilSense para clasificar el modo de falla (Fault Effect).
SMOTE	Técnica de balanceo de datos (Synthetic Minority Oversampling Technique) usada durante el entrenamiento para compensar el desbalance entre clases.

13. Soporte y Contacto


Para reportar errores, solicitar nuevas funcionalidades o consultas técnicas sobre el sistema OilSense ML, contactar al equipo de desarrollo:

Rol	Responsable	Institución
Desarrollo ML y datos	Ing. Daniel Arturo Martínez Morales	MIAD — Universidad de los Andes
Desarrollo ML y datos	Ing. Luis Miguel Ortega Cañate	MIAD — Universidad de los Andes

Nota: Este manual corresponde a la versión 1.0 del sistema OilSense ML. Puede actualizarse a medida que el sistema evolucione y se incorporen nuevas funcionalidades.

14. Anexo

10.1 Diagrama esquemático propuesto



10.2 Reporte técnico de Experimentos e iteraciones realizadas

Entrenamiento, Validación y Calibración de Modelos de clasificación de modo de falla

Selección de Variables

El conjunto de predictores finales incluye 21 variables numéricas correspondientes a los resultados fisicoquímicos del análisis de aceite (metales de desgaste, aditivos, contaminantes, propiedades físicas medidas en ppm, ABS/cm o %) y 4 variables categóricas ordinales SACODE derivadas (SACODE_Salud, SACODE_Desgaste, SACODE_Contaminacion, SACODE_General). Se excluyeron las columnas de identificación, las calificaciones de referencia (Assigned Condition Rating, Rule Based Rating, ACR_Homologado) y la variable de flota del espacio de predictores.

Esquema de Entrenamiento y Validación

Se implemento el siguiente esquema de evaluación:

- División train/test: 80% / 20% con estratificación por clase (stratify=y) para preservar las proporciones originales de la variable objetivo en ambos conjuntos.

- Validación cruzada: StratifiedKFold con 5 particiones y shuffle=True sobre el conjunto de entrenamiento balanceado con SMOTE.

Tabla 1, Configuración general de la validación cruzada implementada

Parámetro	Configuración y Justificación
Tipo de CV	StratifiedKFold, preserva la proporción de clases en cada fold
Número de folds	k = 5, balance entre varianza de la estimación y costo computacional
Conjunto de aplicación	Exclusivamente sobre el train balanceado (post-SMOTE)
Normalización	StandardScaler dentro del pipeline para LR, SVM, MLP. Passthrough para RF, XGBoost, LightGBM (invariantes al escalamiento)
Encoding SACODE	OrdinalEncoder con orden explícito: Normal (0) < Advertencia (1) < Crítico (2). Preserva relación ordinal

- Evaluación final: Los modelos entrenados con el conjunto completo de entrenamiento balanceado se evaluaron sobre el conjunto de prueba con la distribución de clases original.

Parametrización de los Modelos

Los hiperparámetros utilizados en el pipeline de entrenamiento global (sobre todos los datos sin segmentar por flota) fueron los siguientes. Los mismos parámetros se aplicaron en los pipelines por flota:

Tabla 2, Hiperparámetros por modelo

Modelo	Hiperparámetros principales
Regresión Logística	max_iter=1000, class_weight='balanced'
Random Forest	n_estimators=400, max_depth=20, class_weight='balanced'
XGBoost	n_estimators=300, max_depth=5, learning_rate=0.05, subsample=0.8, colsample_bytree=0.8
LightGBM	n_estimators=300, max_depth=5, learning_rate=0.05, class_weight='balanced'
SVM	kernel='rbf', C=10, class_weight='balanced', probability=True
MLP	hidden_layer_sizes=(128,64), max_iter=500, early_stopping=True

Métricas de Evaluación y su Justificación

Dado que el problema es de clasificación multiclase con clases desbalanceadas y con asimetría en el costo de los errores, se definieron las siguientes métricas:

- F1-Score Weighted: métrica principal para la validación cruzada. Calcula el F1 de cada clase ponderado por su frecuencia, compensando el efecto del desbalance de clases y resumiendo el balance entre precision y recall.
- Recall de la clase crítica: métrica prioritaria en el conjunto de prueba. Cuantifica la proporción de casos realmente críticos que el modelo identifica correctamente. En este contexto, un Falso Negativo (clasificar como Normal un caso Crítico) tiene un costo operativo mayor que un Falso Positivo (generar una alerta que el analista valida y descarta). La detección de metales de desgaste elevados (High Wear Metals) o de condición crítica es el requerimiento de mayor valor para el negocio.

- F1-Score de la clase crítica: complementa al recall de la clase crítica, incorporando la precisión para evitar una explosión de falsas alarmas.
- AUC-ROC Weighted (one-vs-rest): métrica de capacidad discriminativa global del modelo sobre las tres clases, independiente del umbral de clasificación.
- Accuracy: métrica de referencia, reportada pero no usada como criterio principal de selección debido al desbalance de clases.

Análisis de Resultados y Selección de Modelos

Resultados del Pipeline Global (todas las flotas)

La primera iteración de pruebas se realizó con los datos de todas las flotas combinados. Los modelos de ensamble basados en arboles de decisión (Random Forest, XGBoost y LightGBM) presentaron el mejor desempeño en F1 Weighted durante la validación cruzada. Sin embargo, al evaluar sobre el conjunto de prueba con la distribución original, el recall de la clase crítica bajo drásticamente en todos los modelos. Este hallazgo reveló que el desbalance residual de la clase crítica (3.6% del total) no es completamente compensado por SMOTE ni por los pesos de clase cuando se mezclan datos de múltiples flotas con comportamientos fisicoquímicos distintos.

Este hallazgo motivó la estrategia de segmentación por flota: al separar los datos por tipo de maquinaria y recalcular los límites SACODE específicos para cada grupo, se espera que los modelos capturen mejor los patrones de desgaste propios de cada flota y mejoren el recall de la clase crítica.




Ilustración 1, Resultados de la primera iteración (Todas las flotas)

En términos generales, los modelos evaluados presentan un buen desempeño discriminativo, con valores de AUC superiores a 0.85 y un F1-Score alto en la mayoría de los casos. No obstante, se identificaron limitaciones relevantes para el modo de falla asociado a altos metales, definido como crítico dentro del proyecto, el Recall no alcanza el umbral mínimo establecido. Por su parte, el modelo de regresión logística registró los resultados más bajos en todas las métricas evaluadas, lo cual era previsible dado que sus supuestos básicos no se cumplen en este contexto; este modelo se incluyó únicamente como referencia comparativa y su comportamiento confirma la complejidad del problema de clasificación abordado.

Las matrices de confusión (Ver notebook “Modelos_Ensamble.ipynb” sección desarrollo de modelos de aprendizaje) y los indicadores de desempeño obtenidos evidencian que los modelos no logran segregar de manera adecuada los ocho modos de falla, lo que sugiere la existencia de comportamientos similares dentro de la misma población de datos que generan clasificaciones ambiguas. Ante esta situación, el área de confiabilidad de la organización planteó que el contexto operativo de cada tipo de flota puede determinar distribuciones y comportamientos distintos en las variables predictoras. Con base en esta recomendación, se tomó la decisión de segmentar los datos por flota y aplicar la metodología de clasificación de SACODE de forma independiente para cada una, aprovechando la distribución propia de sus variables. Adicionalmente, se contempla el uso de SMOTE

para balancear los modos de falla al interior de cada flota y mejorar así la capacidad de generalización de los modelos.

NOTA: Se exploró usar PCA para evitar problemas de multicolinealidad y reducir dimensionalidad en el modelo de regresión logística, sin embargo, los resultados obtenidos no lograron superar las métricas obtenidas por regresión logística sin PCA. Ver sección Enfoque PCA Regresión Logística en el notebook “Modelos_Ensamble.ipynb”.

Resultados por Flota

Se entrenaron y evaluaron modelos independientes para Flota_1 y Flota_2 utilizando los limites SACODE calculados específicamente para cada grupo. En ambas flotas se aplicó el mismo conjunto de seis algoritmos y el mismo esquema de validación (5-Fold StratifiedKFold + evaluación en test). La variable objetivo utilizada en los modelos por flota es Fault Effect, que clasifica las muestras en categorías modo de falla relevantes para el mantenimiento. Ver sección Modelo Flota 1 y Modelo Flota 2 en el notebook “Modelos_Ensamble.ipynb”.

NOTA: A partir de los resultados obtenidos en esta etapa se toma la decisión de incluir la flota con un feature del problema de clasificación.

Resultados de enfoque unificado con flota como Feature

En este enfoque se calcularon las categorías de SACODE usando los limites estadísticos propios de cada flota. También se balancearon los conjuntos de flotas por modos de falla. Estos datos fueron luego agregados en un solo set de datos sobre el cual se volvieron a correr los modelos seleccionados obteniendo los siguientes resultados:




Ilustración 2, Resultados del enfoque unificado sobre la muestra de Test

Tabla 3, Resultados luego de Validación cruzada.

Modelo	F1 Weighted (CV)	Std (±)	Recall W.	Accuracy
LightGBM	0.9942	±0.0007	0.9942	0.9942
Random Forest	0.9924	±0.0011	0.9924	0.9924
XGBoost	0.9905	±0.0010	0.9905	0.9905
MLP	0.9883	±0.0030	0.9884	0.9884
SVM	0.9717	±0.0011	0.9723	0.9723

Logistic Regression	0.7778	± 0.0086	0.7763	0.7763
---------------------	--------	--------------	--------	--------

LightGBM presenta la menor varianza (± 0.0007), indicando alta estabilidad entre folds. Regresión Logística muestra la mayor varianza (± 0.0086), coherente con su menor capacidad de capturar relaciones no lineales entre los predictores fisicoquímicos. Los modelos de ensamble presentan $F1 > 0.99$ con $std < 0.003$, confirmando ausencia de sobreajuste severo en el espacio de entrenamiento balanceado.

A continuación, se muestra los resultados de los diferentes modelos para la predicción de los modos de falla.

1. Modo de Falla: No Fault Identified

Modelo	Correctas	% Correcto	Observación
LightGBM	1,250	98.1%	Mínimos falsos positivos, mejor modelo
Random Forest	1,232	96.7%	Muy sólido en clase mayoritaria
XGBoost	1,221	95.8%	53 confundidas con otras clases
MLP	1,170	91.8%	104 mal clasificadas
SVM	1,133	88.9%	141 mal clasificadas, mayor dispersión
Logistic Regression	803	63.0%	471 mal clasificadas, inaceptable en producción

2. Modo de Falla: Abnormal Combustion

Modelo	Recall	Correctas/83	Observación
Random Forest	90.4%	75/83	Mejor detección de Abnormal Combustion
LightGBM	86.7%	72/83	Segunda mejor, 4 confundidas con No Fault
XGBoost	80.7%	67/83	9 confundidas con No Fault, 6 con High Wear Metals
Logistic Regression	67.5%	56/83	11 confundidas con No Fault
SVM	65.1%	54/83	Mayor dispersión: 15 confundidas con High Wear Metals
MLP	59.0%	49/83	Peor detección, 23 confundidas con No Fault


3. Modo de Falla: High Wear Metals (Modo de Falla Critico)

Modelo	Recall	Correctas/47	Observación
LightGBM	83.0%	39/47	Mayor Recall en esta clase crítica
SVM	80.9%	38/47	Competitivo en esta clase
Random Forest	78.7%	37/47	Estable
MLP	78.7%	37/47	Similar a RF
XGBoost	72.3%	34/47	11 confundidas con No Fault
Logistic Regression	59.6%	28/47	Más confusiones con No Fault

4. Modo de Falla: Fluid Condition Deteriorating

Modelo	Recall	Correctas/34	Observación
Random Forest	85.3%	29/34	Mejor desempeño, empatado con LightGBM
LightGBM	85.3%	29/34	Igual que RF, 5 confundidas con No Fault
XGBoost	76.5%	26/34	8 confundidas con No Fault
SVM	47.1%	16/34	Alta confusión, 15 clasificadas como No Fault
Logistic Regression	47.1%	16/34	Similar a SVM en esta clase
MLP	41.2%	14/34	Mayor número de confusiones, 18 con No Fault

Para complementar el análisis realizado a partir de la matriz de confusión se grafican las curvas ROC comparativa sobre el conjunto de prueba consolidado, este indicador muestra la capacidad discriminativa global de cada modelo, independientemente del umbral de decisión. Un AUC alto garantiza que el modelo tiene capacidad real de distinguir entre clases, aunque el umbral default no sea óptimo.



Modelo	AUC-ROC	Ranking	Interpretación
Random Forest	0.9831	#1	Mejor capacidad discriminativa global
LightGBM	0.9780	#2	Muy competitivo, menor gap vs RF
XGBoost	0.9751	#3	Sólido, mejor F1 Weighted en test
SVM	0.9525	#4	Bueno, gap notable vs ensambles
MLP	0.9286	#5	Aceptable, mayor variabilidad
Logistic Regression	0.8748	#6	Limitado, relaciones lineales insuficientes

Todos los modelos superan $AUC=0.87$, confirmando que el sistema tiene capacidad discriminativa real. El AUC de RF (0.9831) indica que en el 98.3% de los casos el Ariel (Cuerpo) modelo asigna mayor probabilidad a la clase correcta que a una clase incorrecta seleccionada aleatoriamente.

Tabla 4, Resumen de comparación de modelos luego de enfoque unificado

Criterio	LightGBM	XGBoost	RF	SVM	MLP
F1 CV (balanceado)	0.9942 ★	0.9905	0.9924	0.9717	0.9883
F1 Test (real)	0.8414	0.8571 ★	0.8538	0.8185	0.8265
AUC-ROC global	0.9780	0.9751	0.9831 ★	0.9525	0.9286
Estabilidad CV (std)	±0.0007 ★	±0.0010	±0.0011	±0.0011	±0.0030
No Fault Recall	98.1% ★	95.8%	96.7%	88.9%	91.8%
Interpretabilidad (SHAP)	Sí ★	Sí ★	Sí	No	No

La selección de LightGBM como modelo definitivo para la clasificación de modos de falla se fundamenta en un análisis multi-criterio que lo posiciona como el modelo más equilibrado entre capacidad predictiva, estabilidad, eficiencia computacional e interpretabilidad:

- **Capacidad discriminativa por clase:** LightGBM supera a XGBoost en 7 de 8 modos de falla en el , con las mayores ventajas en Fuel Entry ($\Delta=0.014$) y Coolant Entry ($\Delta=0.009$). Es el único modelo con AUC >0.97 en 7 clases simultáneamente.
- **Estabilidad en validación cruzada:** Presenta la menor varianza entre todos los modelos evaluados, lo que indica que su desempeño es consistente independientemente de la partición de datos utilizada. Esta propiedad es crítica en un entorno de producción donde los datos de entrada cambian con el tiempo.
- **Control de falsas alarmas:** Al clasificar correctamente el 98.1% de las muestras sin falla, LightGBM minimiza las intervenciones de mantenimiento innecesarias, reduciendo el costo operativo asociado a falsas alertas. Este valor supera al de XGBoost (95.8%) y Random Forest (96.7%).
- **Eficiencia computacional:** LightGBM utiliza un algoritmo de construcción de árboles basado en histogramas que lo hace significativamente más rápido que XGBoost en inferencia, lo cual es relevante dado que el sistema opera en despliegue local sin infraestructura cloud.
- **Interpretabilidad:** Compatible con SHAP TreeExplainer, lo que permite explicar cada predicción individual al analista de confiabilidad, fortaleciendo la confianza y adopción del sistema por parte del equipo técnico.

El notebook “Modelos_Ensamble.ipynb” contiene el código completo de entrenamiento y evaluación incluyendo las matrices de confusión y las comparativas de métricas por modelo.

Ajustes Implementados

Como resultado del análisis de la primera iteración, se implementaron los siguientes ajustes:

- **Segmentación del modelo por flota:** en lugar de un modelo único global, se entrenaron modelos especializados para cada flota, con sus propios límites condenatorios SACODE.
- **Recalculo de límites SACODE por flota:** los histogramas por predictor segmentados por flota confirmaron diferencias significativas en las distribuciones, justificando límites independientes.
- **Ajuste experto de límites:** para Sodio (advertencia: 40 ppm, crítico: 100 ppm), Oxidación JOAP (advertencia: 19 ABS/cm, crítico: 21 ABS/cm), Cobre (advertencia: 6 ppm, crítico: 8 ppm) y Plomo (advertencia: 4 ppm, crítico: 6 ppm), se incorporaron los criterios del cliente sobre los límites estadísticos calculados automáticamente.


- **Ajuste de k_neighbors en SMOTE** para Flota_2 (k=4), dado el menor número de muestras disponibles en esa flota.
- **Exploración de PCA + Regresión Logística** como alternativa de reducción de dimensionalidad, incluyendo la selección del número óptimo de componentes basada en la varianza acumulada explicada.

Los criterios que guiarán la evaluación final del prototipo son: recall de la clase crítica superior a 0.70, F1-Score Weighted superior a 0.70 en el conjunto de prueba, y AUC-ROC superior a 0.85, todo ello evaluado sobre datos con la distribución de clases real (sin balanceo artificial).

Desarrollo de modelo de clasificación de severidad

Se probaron 2 enfoques para el desarrollo de este modelo:

- Sin balanceo de clases y Feature “Fault Effect” como predictor



En el proceso

de asignación de severidad de la condición, el modo de falla identificado en la muestra constituye un insumo determinante para el analista de confiabilidad. Esta variable no solo orienta la clasificación del nivel de severidad (Normal, Advertencia, Crítico) sino que define directamente la prioridad de atención del activo, dado que distintos modos de falla implican diferentes velocidades de deterioro y potenciales consecuencias operativas.

Por esta razón, y con el objetivo de replicar fielmente la lógica de decisión del analista experto, el modo de falla fue incorporado como una feature adicional en el proceso de clasificación supervisada. Su inclusión busca enriquecer la capacidad discriminativa de los modelos al introducir información cualitativa del diagnóstico que complementa las variables fisicoquímicas numéricas.


Respecto al tratamiento de esta variable, se tomó la decisión técnica de no aplicar balanceo de clases (SMOTE) sobre el modo de falla. Esta decisión se fundamenta en que, a diferencia de las variables numéricas donde SMOTE genera muestras sintéticas mediante interpolación entre vecinos cercanos en el espacio de features, el modo de falla es una variable categórica que representa una condición real diagnosticada por un analista.

Los seis modelos evaluados muestran un desempeño general aceptable en F1 Weighted (todos por encima de 0.80) y AUC-ROC (todos por encima de 0.85), con LightGBM y XGBoost liderando en la primera métrica y XGBoost junto a Random Forest en la segunda.

Sin embargo, el Recall Crítico, la métrica más importante desde la perspectiva de negocio, es insuficiente en todos los modelos, sin que ninguno supere el valor de 0.65. Este resultado era previsible dado que en esta corrida no se aplicó balanceo de clases detrimento de la detección de casos críticos.

Para la siguiente iteración se prevé incorporar SMOTE para balancear las clases y mejorar la sensibilidad sobre los eventos de mayor severidad. Adicionalmente, deberá verificarse la disponibilidad del feature Fault Effect en el flujo de producción, dado que su ausencia en tiempo real comprometería la viabilidad del modelo desplegado.

- Con balanceo de clases sin incluir “Fault Effect” como predictor



Los modelos mantienen un AUC-ROC aceptable (todos por encima de 0.82), liderado por Random Forest y XGBoost, lo que indica que la capacidad de clasificación global se preserva. Sin embargo, el F1 Weighted muestra una caída respecto a la corrida anterior, con MLP (0.741) y Regresión Logística (0.667) rezagándose notablemente, lo que puede atribuirse al efecto del balanceo sobre la distribución de predicciones en clases mayoritarias.

La elección del modelo de clasificación de severidad no responde a una métrica aislada sino a un análisis multicriterio que considera simultáneamente el desempeño global, la capacidad discriminativa y el comportamiento específico sobre la clase minoritaria de mayor impacto operacional (severidad crítica).

Random Forest obtiene el valor más alto de F1 Weighted en el conjunto de prueba con 0.8472, superando a LightGBM (0.8322), SVM (0.8239), XGBoost (0.8222), MLP (0.7904) y Regresión Logística (0.7524). Esta métrica es relevante en contextos de desbalance de clases porque pondera el F1 de cada clase por su frecuencia relativa, ofreciendo una visión equilibrada del comportamiento del modelo sobre toda la distribución de datos. Un F1 Weighted de 0.8472 indica que el modelo mantiene un balance adecuado entre Precisión y Recall en las tres clases (Normal, Warning y Critical) simultáneamente.

Recall Crítico — métrica de seguridad operacional

Random Forest comparte con SVM el valor más alto de Recall para la clase Critical con 0.7778, seguido por Regresión Logística y MLP (0.7037), LightGBM (0.6296) y XGBoost (0.5926). En el contexto de este problema, el Recall de la clase Critical es la métrica de mayor peso operacional porque cuantifica la proporción de fallas críticas reales que el modelo detecta correctamente. Como se argumenta en la sección de riesgos, el costo de un falso negativo en esta clase, dejar pasar una condición crítica sin alertar, es significativamente más alto que el costo de un falso positivo. Por tanto, maximizar el Recall de Critical es una exigencia del negocio que debe ponderarse al mismo nivel que las métricas globales.

AUC-ROC — capacidad discriminativa


En el área bajo la curva ROC, Random Forest obtiene el valor más alto del conjunto con 0.8995, seguido por XGBoost (0.8897), LightGBM (0.8812), MLP (0.8621), SVM (0.8442) y Regresión Logística (0.8310).

Con base en los resultados anteriores Random Forest es seleccionado como modelo de clasificación de severidad por ser el único algoritmo que alcanza simultáneamente el mayor F1 Weighted (0.8472), el mayor Recall de la clase Critical (0.7778) y el mayor AUC-ROC (0.8995) en el conjunto de prueba.

Interpretabilidad de los modelos de Severidad.

Una vez seleccionado el Random Forest como modelo de clasificación de severidad, el paso siguiente consiste en comprender qué variables fisicoquímicas determinan cada predicción y en qué medida lo hacen. Para esto se implementó el framework SHAP — SHapley Additive exPlanation

El análisis global examina el comportamiento del modelo sobre el conjunto completo de muestras, identificando qué variables son sistemáticamente más relevantes para clasificar una muestra como Critical en toda la flota.



Las cinco variables de mayor impacto medio absoluto, ordenadas por relevancia, son las siguientes:

1. Hierro (ppm) encabeza el ranking con un SHAP medio absoluto de 0.0874. Los puntos rojos muestras con Hierro alto se concentran a la derecha del cero, confirmando que concentraciones elevadas empujan consistentemente hacia Critical.
2. SACODE_General ocupa la segunda posición con un SHAP medio de +0.0713 en dirección positiva. Su comportamiento confirma la coherencia interna del sistema: muestras cuya calificación SACODE general ya es Crítico reciben un impulso consistente hacia la clase Critical

del modelo predictivo, validando que el módulo descriptivo basado en reglas y el módulo predictivo basado en Machine Learning convergen hacia el mismo diagnóstico.

3. Sodio (ppm), Plomo (ppm) y Cobre (ppm) Los puntos rojos muestras con estos predictores metálicos alto se concentran a la derecha del cero, confirmando que concentraciones elevadas empujan consistentemente hacia Critical.
4. Silicio (ppm), Los puntos rojos muestras con este predictor relacionado con la contaminación de aceite alto se concentran a la derecha del cero, confirmando que concentraciones elevadas empujan consistentemente hacia Critical.

10.3 Archivos de código desarrollados para la implementación del prototipo

Los modelos y códigos desarrollados para este proyecto se encuentran disponibles en el repositorio de GIT para su inspección y evaluación, el link de acceso es

Link Repo: <https://github.com/darturo12/Tesis-de-Grado-MIAD->