



Oil Sense ML

DANIEL ARTURO MARTINEZ M.

LUIS MIGUEL ORTEGA C.

Nota de Confidencialidad



El presente documento contiene información técnica, operativa y analítica basada en datos internos suministrados por la organización colaboradora. Dichos datos, así como los resultados, modelos, hallazgos y conclusiones aquí desarrollados, son estrictamente confidenciales y han sido utilizados únicamente con fines académicos y de análisis interno del proyecto.

Queda prohibida la reproducción, divulgación, distribución o uso parcial o total de la información contenida en este documento sin la autorización previa y por escrito de la organización propietaria de los datos. Cualquier uso no autorizado podrá constituir una infracción a las políticas internas de la empresa y a la normativa aplicable en materia de manejo de información sensible.

El contenido de este informe no debe ser interpretado como una publicación oficial ni como un documento destinado a circulación externa.



PROYECTO – IMPLEMENTACIÓN DE UN SISTEMA DE CLASIFICACIÓN DE RESULTADOS DE ANÁLISIS DE ACEITE USADO PARA MOTORES DE MAQUINARIA PESADA EN LA INDUSTRIA MINERA



Daniel Arturo Martínez Morales
Aspirante a título de maestría MIAD
Universidad de los Andes

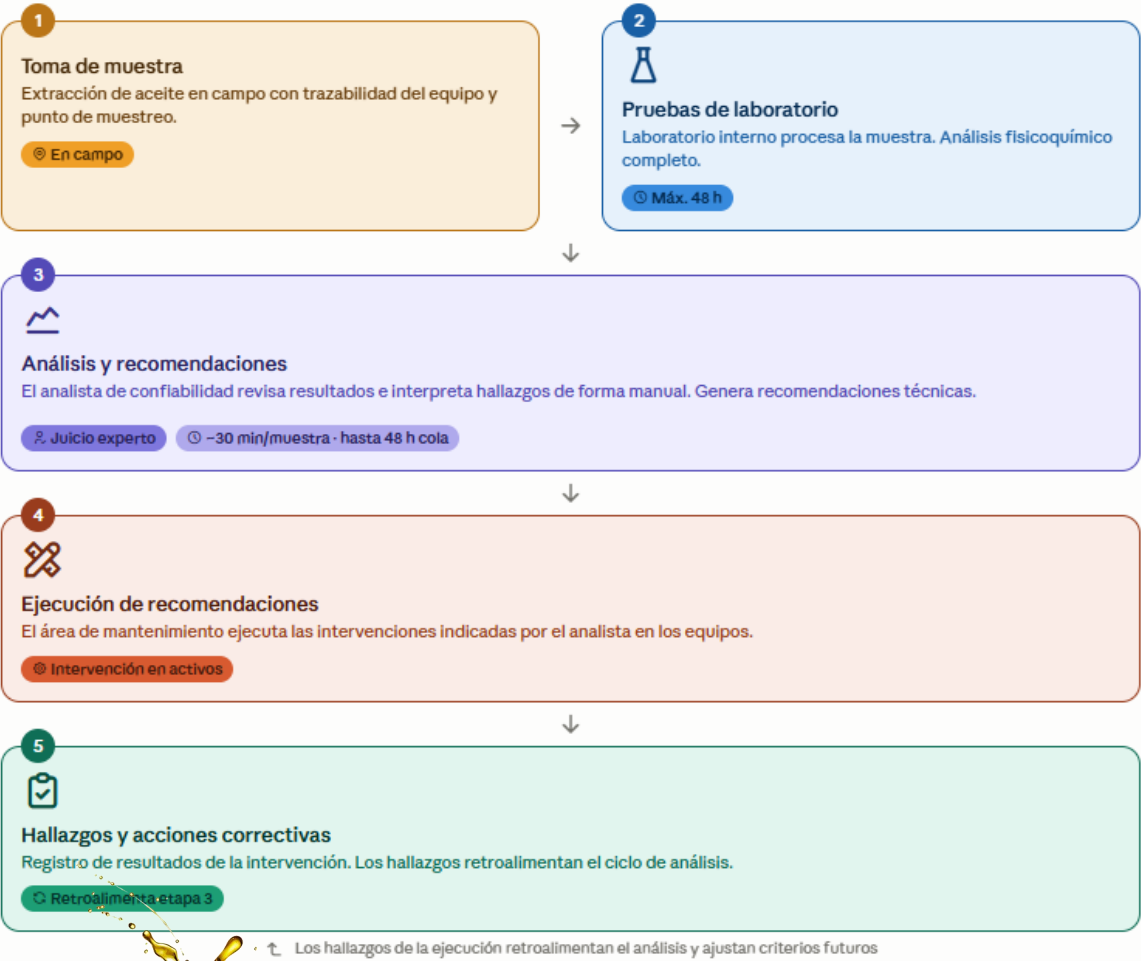


Luis Miguel Ortega Cañate
Aspirante a título de maestría MIAD
Universidad de los Andes



PROBLEMA DE NEGOCIO – DEPARTAMENTO DE MANTENIMIENTO DE UNA ORGANIZACIÓN MINERA

PROCESO ACTUAL – ANALISIS DE ACEITE LUBRICANTE



OPORTUNIDADES DEL PROCESO

- Carga del analista
 - ~15 h/semana revisando muestras (~40% del tiempo)
 - Alto volumen: hasta 48 h de espera entre resultados y análisis completo
 - Evaluación dependiente del criterio individual del analista

- Limitaciones del proceso
 - Inconsistencias por diferencias de experiencia entre analistas
 - Sin alertas tempranas ni modelos predictivos
 - Datos subutilizados: no alimentan sistemas de diagnóstico avanzado

- Impacto económico estimado
 - Pérdidas anuales cercanas a \$500 kUSD asociadas a fallas no detectadas a tiempo por evaluaciones manuales tardías o inconsistentes.

- Oportunidad estratégica
 - Aprovechar el conocimiento del equipo de confiabilidad para crear modelos analíticos que mejoren el rendimiento de los activos y sienten las bases de la transformación digital de la gestión de activos en el holding.

PROPUESTA ANALÍTICA

- Desarrollar un modelo de aprendizaje automático supervisado para la automatización de la detección e interpretación de modos de falla en los resultados de análisis de aceite usado, integrando la metodología SACODE y el registro histórico de anomalías de la base de datos de mantenimiento, con el fin de analizar y optimizar el desempeño predictivo del sistema de monitoreo de condición de motores de flotas de equipos mineros.








DIAGRAMA ESQUEMATICO DE LA SOLUCION PLANTEADA

PIPELINE DE DESARROLLO – MODELOS DE MACHINE LEARNING



RESULTADOS DEL DESARROLLO – MODELOS DE MACHINE LEARNING



Modelo multiclase — modo de falla

Clasificación de anomalías en aceite lubricante · maquinaria pesada

Modelo seleccionado: LightGBM

AUC — capacidad de generalización

El modelo distingue correctamente entre clases en casi todos los casos, incluso ante datos no vistos

0.9897

Recall — clase crítica: altos metales de desgaste

Falla más severa posible en un motor · el modelo detecta el 85% de los casos reales

0.8511

Exactitud (accuracy)

96%

Predicciones correctas sobre el total

F1 ponderado

0.9642

Balance precisión–recall entre clases

Búsqueda aleatoria

500 entrenamientos

Búsqueda en cuadrícula

400 entrenamientos

Hiperparámetros finales

Tasa de aprendizaje	0.0772	Árboles (estimadores)	346
Hojas por árbol	61	Profundidad máxima	10
Submuestreo de filas	0.648	Submuestreo de columnas	0.572
Muestras mín. por hoja	27	Peso de clase	balanceado
Regularización L1	0.0	Regularización L2	0.0

Modelo binario — severidad de falla

Clasificación Warning / Critical · análisis de aceite lubricante

Modelo seleccionado: Random Forest

Warning

Anomalía presente, monitorear

Critical

Intervención inmediata requerida

AUC — capacidad de generalización

El modelo separa correctamente los casos Warning y Critical en el 90% de los casos, incluso ante datos no vistos

0.8995

Recall — clase crítica: Critical

Casos que requieren intervención inmediata · el modelo detecta el 78% de los casos reales

0.7778

Exactitud (accuracy)

84%

Predicciones correctas sobre el total

F1 ponderado

0.8472

Balance precisión–recall entre clases

Búsqueda aleatoria

400 entrenamientos

Búsqueda en cuadrícula


810 entrenamientos

Hiperparámetros finales

Árboles (estimadores)	610	Profundidad máxima	12
Variables por división	todas	Muestras mín. por hoja	1
Muestras mín. para dividir	2	Peso de clase	bal. submuestreo



PROTOTIPO FACHADA - OIL SENSE ML




Costos evitados

Salidas de modelos de ML

Indicadores relevantes para nivel gerencial

Información de detalles y clasificaciones automáticas del modelo para nivel operativo

Acciones recomendadas basadas en la clasificación del modo de falla y la criticidad asignada.



DASHBOARD IMPLEMENTADO- OIL SENSE ML

Costos evitados

Acciones recomendadas
basadas en la clasificación
del modo de falla y la
criticidad asignada.

Información de detalles y
clasificaciones automáticas del
modelo para nivel operativo

Interpretabilidad de los resultados

Salidas de modelos de ML

Análisis Descriptivo de
variables



IMPACTO ESPERADO



Indicador	Objetivo	Tipo
Tiempo de Procesamiento de muestras	Reducción del tiempo de procesamiento de muestras de aceite usado en un 30% .	Negocio
Ahorros conseguidos a partir de la identificación de modos de falla de manera oportuna	Aumento en un 15 % en los ahorros conseguidos por la identificación oportuna de condiciones de falla potenciales	Negocio
Nivel de satisfacción	>80% de los usuarios perciban que las alertas y recomendaciones proporcionadas por el modelo sean relevantes y pertinentes para la toma de decisiones preventivas	Negocio



CONSIDERACIONES FINALES

Limitaciones

- Entrenado solo para 3 flotas en específico
- Despliegue sin nube (Acuerdo de confidencialidad)
- El recall de la clase crítica del modelo de clasificación de de severidad es inferior al 80% propuesto
 - Revisión de calidad detallada de los datos de entrada
 - Mesas técnicas con expertos para desarrollo de nuevas características

Costos

- Horas hombre (2 Científicos de datos): 240 horas
- Licencias: 0

Riesgos

- Falta de evaluaciones en bloque automáticas (actualización manual de los datos de inicio)
- Costo alto de falsos negativos

Condiciones de despliegue

- Despliegue local escalable a maquinas virtuales en entorno onpremise de la organización



Gracias

MIAD 2026

