

PROYECTO – IMPLEMENTACIÓN DE UN SISTEMA DE CLASIFICACIÓN DE RESULTADOS DE ANÁLISIS DE ACEITE USADO PARA MOTORES DE MAQUINARIA PESADA EN LA INDUSTRIA MINERA

Ing. Daniel Arturo Martínez Morales

Aspirante a título de maestría MIAD, Universidad de los Andes

Ing. Luis Miguel Ortega Cañate

Aspirante a título de maestría MIAD, Universidad de los Andes

ABSTRACT

The project aims to automate and optimize the oil analysis process used to assess the condition of critical fleet components. Currently, each reliability analyst spends an average of 15 hours per week processing results, with 58% of that time dedicated to manual sample evaluation, failure mode assignment, and severity classification. This operational burden, combined with the variability inherent to individual judgment, contributes to annual losses of approximately 500 kUSD due to the late identification of abnormal conditions that evolve into functional failures.

The proposed solution integrates advanced analytics and automation tools to reduce processing times, standardize diagnostics, and enhance early detection of risk conditions. The initiative seeks to strengthen operational reliability, reduce economic losses associated with undetected failures, and establish a more efficient, consistent, and data-driven predictive maintenance process.

RESUMEN

El proyecto tiene como objetivo automatizar y optimizar el proceso de análisis de aceite utilizado en la evaluación de la condición de componentes críticos de la flota. Actualmente, cada analista de confiabilidad dedica en promedio 15 horas semanales al procesamiento de resultados, destinando el 58% de ese tiempo al análisis manual de muestras, asignación de modos de falla y determinación de severidad. Esta carga operativa, sumada a la variabilidad asociada al criterio individual, contribuye a que se presenten pérdidas anuales cercanas a 500 kUSD derivadas de la identificación tardía de condiciones anómalas que evolucionan hacia fallas funcionales.

La solución propuesta implementa herramientas de analítica avanzada y automatización para disminuir los tiempos de procesamiento, estandarizar los diagnósticos y mejorar la detección temprana de condiciones de riesgo. Con ello se busca fortalecer la confiabilidad operacional, reducir pérdidas económicas por fallas no detectadas oportunamente y consolidar un proceso de mantenimiento predictivo más eficiente, consistente y basado en datos.

Nota de Confidencialidad

El presente documento contiene información técnica, operativa y analítica basada en datos internos suministrados por la organización colaboradora. Dichos datos, así como los resultados, modelos, hallazgos y conclusiones aquí desarrollados, son estrictamente confidenciales y han sido utilizados únicamente con fines académicos y de análisis interno del proyecto.

Queda prohibida la reproducción, divulgación, distribución o uso parcial o total de la información contenida en este documento sin la autorización previa y por escrito de la organización propietaria de los datos. Cualquier uso no autorizado podrá constituir una infracción a las políticas internas de la empresa y a la normativa aplicable en materia de manejo de información sensible.

El contenido de este informe no debe ser interpretado como una publicación oficial ni como un documento destinado a circulación externa.

Tabla de Contenido

Nota de Confidencialidad	2
Identificación del usuario y problema de negocio	4
Planteamiento del problema de negocio.....	5
Identificación de Stakeholders	5
Formulación de requerimientos.....	6
Métricas claves, KPIs e Impacto esperado	8
Descripción funcional del artefacto	9
Definición de modelos / análisis	11
Datos: Fuentes, Acceso, Procesamiento (ETL)	11
Técnicas de limpieza de datos.....	18
Diagrama esquemático	21
MockUp / Storyboard.....	22
Referencias	25

Tabla de ilustraciones

Ilustración 1, Matriz de correlación de datos faltantes	15
Ilustración 2, Análisis de distribución de variables numéricas	16
Ilustración 3, Análisis comparativo de medias de variables numéricas frente a las clases de la variable "Severidad"	17
Ilustración 4, Diagrama esquemático	21
Ilustración 5, MockUp del dashboard a implementar	22

Listado de tablas

Tabla 1, Evaluación de requerimientos por viabilidad e impacto.	7
Tabla 2, Aporte de los requerimientos funcionales a los criterios de éxito del proyecto.	8
Tabla 3, Aporte de los requerimientos no funcionales a los criterios de éxito del proyecto.	8
Tabla 4, Descripción de variables del conjunto de datos	12
Tabla 5, Esquema de tratamiento de datos faltantes	18
Tabla 6, Análisis de validez de rango de las variables numéricas	19
Tabla 7, Esquema de tratamiento de datos atípicos	20

Identificación del usuario y problema de negocio

En la industria minera, el mantenimiento de maquinaria pesada como camiones OHT y excavadoras es crítico para garantizar la continuidad operativa y evitar interrupciones de alto costo. Entre las herramientas predictivas más utilizadas, el análisis de aceite usado permite evaluar el estado de salud de componentes mecánicos, detectar contaminación, desgaste acelerado y degradación del lubricante, anticipándose a fallas funcionales que pueden comprometer la disponibilidad de la flota.

Sin embargo, la interpretación de estos análisis depende en gran medida del criterio experto de los analistas de confiabilidad. Actualmente, cada analista invierte en promedio 15 horas semanales en el procesamiento de resultados, destinando el 58% de ese tiempo al análisis manual de muestras, la asignación de modos de falla y la determinación del nivel de severidad. Este proceso, altamente dependiente del juicio individual, introduce variabilidad en los diagnósticos, genera tiempos de respuesta prolongados y reduce la capacidad para identificar oportunamente condiciones críticas. Como consecuencia, la organización enfrenta pérdidas anuales cercanas a 500 kUSD asociadas a fallas que no fueron detectadas a tiempo debido a evaluaciones manuales tardías o inconsistentes.

En este contexto, la automatización del proceso de clasificación y diagnóstico no solo representa una necesidad operativa, sino una oportunidad estratégica para estandarizar los criterios de evaluación, reducir los tiempos de procesamiento y mejorar la detección temprana de condiciones anómalas. La incorporación de herramientas de analítica avanzada permite transformar el conocimiento experto en un modelo reproducible, consistente y escalable, fortaleciendo el mantenimiento predictivo, mejorando la confiabilidad operacional y disminuyendo significativamente el impacto económico de las fallas no anticipadas. Actualmente, la empresa dispone de una amplia base de datos proveniente de programas de monitoreo de condición, entre ellos el análisis de aceite usado, que contiene información valiosa sobre el desgaste interno, la contaminación y el estado general de los motores. Sin embargo, gran parte de estos datos se encuentran subutilizados o analizados de forma reactiva, limitando la posibilidad de anticipar fallas y optimizar los intervalos de mantenimiento.

En este contexto, surge la necesidad de desarrollar un proyecto de analítica avanzada que permita integrar, procesar y modelar los datos de análisis de aceite para identificar comportamientos anómalos y tendencias de deterioro. Este proyecto busca fortalecer la estrategia de mantenimiento predictivo de la organización, alineándose con los objetivos corporativos de eficiencia operacional, reducción de costos y transición hacia decisiones basadas en datos (data-driven). Además, responde a una oportunidad estratégica: aprovechar las capacidades analíticas internas y el conocimiento técnico del equipo de confiabilidad para crear modelos que no solo mejoren el rendimiento de los activos actuales, sino que sienten las bases para la transformación digital de la gestión de activos dentro del holding.

Con el fin de abordar esta problemática, el proyecto tiene como propósito desarrollar un modelo analítico basado en modelos de aprendizaje supervisado que permita automatizar la detección e interpretación de modos de falla a partir de los resultados históricos del análisis de aceite. El modelo integrará la metodología SACODE como marco de interpretación estandarizada para clasificar muestras, identificar comportamientos anómalos y priorizar alertas de mantenimiento predictivo.

Planteamiento del problema de negocio

La interpretación manual de los resultados de análisis de aceite usado presenta varios desafíos:

- Alta dependencia del juicio experto y de la disponibilidad del analista.
- Inconsistencias en las evaluaciones debidas a diferencias de experiencia o criterio técnico.
- Retrasos en la entrega de resultados y en la toma de decisiones de mantenimiento.
- Subutilización de la información generada por los análisis, que podría alimentar sistemas avanzados de diagnóstico y pronóstico.
- Altos tiempos entre el procesamiento de la muestra y generación de recomendaciones con base en los hallazgos identificados.

Se requiere un sistema automatizado que permita clasificar de forma consistente y rápida las muestras de aceite usado según criterios estandarizados (metodología SACODE de Noria), indicando el estado del aceite, el nivel de contaminación y el desgaste, además de establecer un nivel de severidad y sugerir acciones básicas de mitigación.

El proyecto de analytics tiene como propósito desarrollar un modelo analítico basado en modelos de aprendizaje supervisado que permita automatizar la detección e interpretación de modos de falla a partir de los resultados históricos del análisis de aceite. El modelo integrará la metodología SACODE como marco de interpretación estandarizada para clasificar muestras, identificar comportamientos anómalos y priorizar alertas de mantenimiento predictivo.

Las técnicas potenciales de Analytics a emplear comprenden:

- **Modelos de aprendizaje automático supervisados** para la clasificación de estados del aceite y predicción de modos de falla.
- **Análisis de importancia de predictores** para identificar el impacto de cada variable en la falla estimada y así comprender los factores de mayor influencia en el deterioro de los motores.
- **Visualizaciones interactivas / Storytelling** para la visualización de los resultados obtenidos del modelo clasificación y análisis descriptivos.

Identificación de Stakeholders

A continuación, se identifican los actores que principalmente se verían afectados y/o beneficiados con el desarrollo del proyecto:

- **Gerentes de mantenimiento:** Son responsables de la gestión integral del mantenimiento y de presentar resultados ante la dirección general. El proyecto los impacta directamente al proporcionar una herramienta que mejora la capacidad de anticipar fallas, optimiza la asignación de recursos y reduce los costos correctivos asociados a diagnósticos tardíos o inconsistentes. Un sistema más confiable de clasificación y alertamiento reduce la incertidumbre operativa, mejora la planificación del mantenimiento y fortalece su capacidad de justificar inversiones con base en evidencia analítica.
- **Directores de gestión de activos:** Definen lineamientos estratégicos para la operación de los procesos de mantenimiento dentro de la organización. El sistema analítico propuesto

refuerza los pilares de confiabilidad, gobernanza y trazabilidad de datos que ellos supervisan. Les permite escalar prácticas predictivas alineadas con estándares corporativos y facilita la transición hacia una gestión predictiva. Su impacto es estratégico, pues el proyecto habilita iniciativas futuras de analítica avanzada dentro del marco de Asset Management.

- **Coordinadores de monitoreo de condiciones:** Son quienes implementan y controlan las rutinas de monitoreo y son responsables de que los indicadores de salud de los componentes cumplan las metas. El proyecto transformará su operación diaria al ofrecerles un sistema automatizado de clasificación de modos de falla y severidades, reduciendo la carga manual, estandarizando criterios y disminuyendo la variabilidad entre analistas. Esto incrementa la velocidad y confiabilidad del proceso y mejora la capacidad para detectar tendencias emergentes.
- **Proveedores de lubricantes:** Son responsables de la calidad y característica técnica de los fluidos utilizados en los equipos. El proyecto impacta su rol al generar una base objetiva de datos que permite identificar anomalías atribuibles a variaciones en formulación, desempeño o compatibilidad con las condiciones de operación. Esto fortalecen la trazabilidad técnica con el proveedor y permite una mejor gestión de garantías, reclamos y ajustes de producto.
- **Analistas de Confiabilidad:** Es el grupo más afectado operacionalmente. El sistema reducirá el tiempo dedicado al análisis manual, aumentará la consistencia en diagnósticos y apoyará su curva de aprendizaje, especialmente para analistas nuevos. También cambiará su rol hacia uno más interpretativo y estratégico.
- **Área de Tecnologías de la Información (TI):** Es responsable de habilitar el acceso a los datos, soportar la infraestructura, garantizar la seguridad de la información y mantener el sistema en producción. El proyecto les exige asegurar integraciones con sistemas existentes, gestionar accesos y brindar soporte continuo.
- **Laboratorio de Análisis de Aceite:** La calidad y consistencia de sus mediciones influye directamente en el desempeño del modelo. El sistema permitirá identificar variaciones por calibración, cambios de formulación o sesgos, y generará retroalimentación que puede exigir ajustes en procedimientos internos.

Formulación de requerimientos

Con base en el análisis Kano¹ desarrollado durante el anteproyecto, los requerimientos del sistema se agrupan según su impacto en la satisfacción del usuario. Los requerimientos “Must-have” corresponden a funciones básicas sin las cuales el sistema no sería aceptado: carga manual de datos. Los requerimientos de “Performance”, que incrementan la satisfacción conforme mejora su

¹ Durante el desarrollo de la asignatura de “Gerencia de proyectos de analytics” se desarrolló la formulación de requerimientos siguiendo la metodología de análisis de Kano. Este análisis sirve para clasificar las características de un producto o servicio según su impacto en la satisfacción del cliente. El modelo propone que no todos los atributos generan satisfacción de la misma manera: algunos son requisitos básicos que el cliente da por sentados y cuya ausencia genera insatisfacción inmediata, otros son atributos de desempeño donde más es mejor, y otros son diferenciadores inesperados que deleitan al cliente cuando aparecen, pero cuya ausencia no genera frustración. Al mapear las características de un producto en estas categorías, se pueden priorizar mejor qué construir primero, qué mejorar y qué innovar, enfocando los recursos en lo que realmente importa para la experiencia del usuario.

desempeño, incluyen: clasificación primaria según SACODE, clasificación de modos de falla, clasificación de la severidad, acceso desde las plataformas habituales, visualización histórica de muestras, posibilidad de comentarios manuales del analista, exportar resultados, generación de recomendaciones básicas, alertas automáticas, interfaz amigable y feedback personalizado. Finalmente, los requerimientos “Attractive”, que sorprenden positivamente al usuario y generan diferenciación, son: correr análisis en lotes en menos de un minuto, carga automática de datos y generar indicadores automáticos de desempeño.

Para la implementación de estos requerimientos deberán involucrarse principalmente las áreas de mantenimiento y confiabilidad, responsables de la interpretación técnica de los análisis; laboratorio de lubricantes, encargado del flujo de datos de las muestras; tecnología e innovación, que desarrollará e integrará la herramienta en la infraestructura existente; y analítica de datos, que definirá los modelos de clasificación y reglas de decisión. La implementación impactará directamente los objetivos del proyecto al mejorar la eficiencia operativa mediante la automatización del diagnóstico, aumentar la precisión y estandarización en las evaluaciones y reducir la dependencia del criterio individual de los analistas. Además, los atributos “Attractive” reforzarán la percepción de valor e innovación del sistema, contribuyendo a una mayor adopción por parte de los usuarios y a un uso más intensivo de los datos para la toma de decisiones en mantenimiento predictivo. A continuación, se provee una calificación realizada por el equipo de trabajo sobre cada requerimiento teniendo en cuenta su viabilidad técnica y el impacto que tendría sobre los objetivos del proyecto.

Tabla 1, Evaluación de requerimientos por viabilidad e impacto.

Requerimientos a incrementar			
Nombre y descripción	Escala de viabilidad en desarrollo e implementación (1-10)	Escala de impacto en el objetivo del proyecto (1-10)	Score total
Correr análisis en lotes en menos de 1 minuto	7	4	5.5
Clasificación primaria según SACODE	8	10	9
Clasificación de modos de falla	9	10	9.5
Clasificación de la severidad	7	10	8.5
Ser accedido fácilmente desde las plataformas que el usuario utiliza habitualmente	4	7	5.5
Carga automática de datos	5	6	5.5
Carga manual de datos	9	6	7.5
Visualización histórica de muestras	9	8	8.5
Posibilidad de introducir comentarios o validaciones manuales del analista	4	6	5
Exportar análisis en formato Excel y PDF	8	7	7.5
Generación de recomendaciones de atención básicas según resultados de clasificación	6	10	8
Generar indicadores automáticos de desempeño	8	8	8
Generar alertas automáticas por correo cuando se detecten resultados críticos	5	6	5.5
Interfaz amigable y personalizable	8	8	8
Posibilidad de enviar feedback personalizado y notificación de errores	4	5	4.5

Luego de revisar estos requerimientos con los stakeholders se decide priorizar aquellos requerimientos con score mayor a 8, permitiendo enfocar mejor los recursos al tiempo que se visualiza una posible fase futura de maduración en donde puedan involucrarse los requerimientos con menor puntuación.

Los requerimientos finales son:

- Clasificación primaria según SACODE
- Clasificación de modos de falla
- Clasificación de la severidad
- Visualización histórica de muestras
- Generación de recomendaciones de atención básicas según resultados de clasificación
- Generar indicadores automáticos de desempeño
- Interfaz amigable y personalizable

A continuación, se valida el aporte que cada requerimiento hace a los criterios de éxito del proyecto y se establecen indicadores que permitirán hacer seguimiento a su grado de implementación.

Tabla 2, Aporte de los requerimientos funcionales a los criterios de éxito del proyecto.

Requerimiento	Categoría	Relación con las métricas de negocio	Indicador asociado
Clasificación primaria según SACODE	Must (Obligatorio)	Permite transformar los resultados de laboratorio en categorías mas simples, base para detectar tendencias de degradación y mejorar decisiones de mantenimiento. - ¿Qué estado de salud presenta el aceite según sus parámetros físico-químicos? - ¿Existe algún factor que sea repetitivo a lo largo de la flota de equipos que indique la necesidad de una iniciativa de mantenimiento transversal o un cambio de estrategia?	Precisión del modelo SACODE = $(N^{\circ} \text{ clasificaciones correctas} / N^{\circ} \text{ total de muestras evaluadas}) \times 100$ >85%
Clasificación de modos de falla	Must (Obligatorio)	Facilita la identificación temprana de patrones de falla recurrentes, contribuyendo a reducir fallas imprevistas. - ¿Qué modo de falla es mas probable dado el perfil de desgaste actual?	Exactitud en detección de fallas = $(N^{\circ} \text{ modos de falla correctamente identificados} / N^{\circ} \text{ modos totales validados}) \times 100$ >80%
Clasificación de la severidad	Must (Obligatorio)	Ayuda a priorizar la atención de equipos según criticidad, reduciendo tiempos de respuesta ante condiciones críticas. - ¿Con qué nivel de urgencia se requiere ejecutar las acciones de mantenimiento asociadas al resultado de esta muestra?	Consistencia en clasificación de severidad = $(N^{\circ} \text{ coincidencias con diagnóstico experto} / N^{\circ} \text{ total de evaluaciones}) \times 100$ >85%
Visualización histórica de muestras	Must (Obligatorio)	Permite analizar tendencias de degradación, validar la permanencia en condiciones específicas y reconocer patrones evolutivos de falla. - ¿Cómo ha evolucionado la condición del componente a lo largo del tiempo?	Disponibilidad del panel histórico = $(N^{\circ} \text{ sesiones con panel histórico} / N^{\circ} \text{ total de sesiones}) \times 100$ >60%
Generación de recomendaciones de atención básicas	Must (Obligatorio)	Aumenta la capacidad de acción inmediata ante hallazgos críticos, reduciendo tiempos de inactividad y costos correctivos. - ¿Qué acción de mantenimiento se recomienda dado el modo de falla y severidad detectados?	Adopción de recomendaciones = $(N^{\circ} \text{ de recomendaciones aceptadas} / N^{\circ} \text{ total de recomendaciones generadas}) \times 100$ >50%
Generar indicadores automáticos de desempeño	Should (Deseable)	Permite medir de forma continua la mejora en confiabilidad y eficiencia del mantenimiento. - ¿Cómo se compara el desempeño operacional actual versus la línea base pre-implementación?	Mejora de MTBF = $(\text{MTBF post-implementación} / \text{MTBF pre-implementación}) - 1$ >10% (en 6 meses)
Importación de variables	Should (Deseable)	Dar trazabilidad técnica al diagnóstico y facilitar validación por parte de expertos. - ¿Qué variable físico-química explica la clasificación asignada?	Disponibilidad del panel de SHAP en cada registro clasificado como crítico = 100%
Interfaz amigable y personalizable	Should (Deseable)	Favorece la adopción del sistema por parte de los usuarios, asegurando su integración en los procesos internos. - ¿El sistema es usable sin capacitación externa por parte de un analista junior?	Nivel de satisfacción del usuario = $(\sum \text{ puntuaciones de satisfacción} / N^{\circ} \text{ encuestas respondidas}) \times 100$ >75%

También se incluyen los requerimientos no funcionales:

Tabla 3, Aporte de los requerimientos no funcionales a los criterios de éxito del proyecto.

Requerimiento	Categoría	Relación con las métricas de negocio
Licenciamiento Open Source	Must (Obligatorio)	Evitar costos de licenciamiento y facilitar mantenimiento interno. (Característica no funcional)
Despliegue local sin nube	Must (Obligatorio)	Cumplir políticas internas de seguridad de la información. (Característica no funcional)

Métricas claves, KPIs e Impacto esperado

El proyecto aportará beneficios técnicos, operativos y financieros, derivados de una detección más oportuna y consistente de condiciones anormales en los componentes lubricados de la flota minera.

Entre los beneficios esperados se destacan:

1. **Reducción de fallas no detectadas y eventos catastróficos:** Al automatizar la detección de anomalías en los análisis de aceite, se espera disminuir el número de fallas mayores que no fueron anticipadas por el sistema actual.
2. **Disminución del tiempo de respuesta en el diagnóstico:**
El sistema automatizado permitirá generar alertas inmediatas una vez recibido un reporte, reduciendo los tiempos de interpretación humana.

3. **Mayor consistencia y objetividad en la interpretación:**
Se eliminará la variabilidad entre analistas, mejorando la confiabilidad de los diagnósticos y la trazabilidad de los criterios utilizados.
4. **Optimización de intervenciones de mantenimiento:**
Al mejorar la precisión del diagnóstico, se espera una mejor priorización de equipos y una planificación más eficiente de los recursos.
5. **Incremento en la disponibilidad y confiabilidad de la flota:**
Menos fallas imprevistas se traducen en mayor tiempo operativo y reducción del costo por hora productiva.
6. **Fortalecimiento de la gestión del conocimiento:**
El modelo servirá como repositorio analítico de experiencia operativa, contribuyendo a la estandarización de criterios técnicos y entrenamiento del personal.

Las métricas principales del negocio incluyen:

- **Tiempo promedio de análisis y diagnóstico:** La organización reporta un tiempo promedio actual de 36 horas mensuales por analista dedicadas al análisis y diagnóstico de muestras. La meta propuesta por la organización es disminuir el tiempo promedio mensual de análisis a menos de 24 horas mensuales.
- **Tasa de fallas no anticipadas por análisis de aceite:** La organización reporta un numero de fallas no previstas de entre 20 y 30 fallas de motores al año no previstas por análisis de aceite. La meta propuesta es disminuir la tasa de falla no previstas en un 10% en el primer año de implementación del artefacto.

Las métricas principales del modelo a desarrollar será la capacidad para detectar fallas críticas.

- **Recall (Sensibilidad) para la Clase “Crítico”: Métrica Técnica Principal.** Mide la proporción de fallas críticas reales que el modelo predice correctamente. Un alto *Recall* es prioritario, pues minimiza los **Falsos Negativos** (fallas catastróficas no anticipadas), que son el mayor riesgo de negocio. La meta esperada para esta métrica es de 0.85 , esto apalancado en trabajos anteriores con similar alcance (estado del arte).

Descripción funcional del artefacto

El artefacto analítico desarrollado corresponde a un sistema de clasificación por lotes (batch) con interfaz de visualización interactiva (dashboard), implementado localmente en Power BI . La solución se compone de dos módulos integrados:

1. Un motor de clasificación supervisado que procesa lotes de datos proveniente del DWH con resultados de análisis de aceite y genera predicciones de severidad, modo de falla y recomendación de atención sobre las condiciones identificadas.
2. Un dashboard interactivo construido que permite al analista de confiabilidad y al equipo de gerencia visualizar resultados del modelo, explorar históricos, exportar reportes visualización de indicadores operativos.

Se optó por un dashboard local sobre Power BI y no por una aplicación web desplegada en la nube ni una API REST, debido a que la organización no cuenta con un entorno cloud habilitado por políticas

internas de seguridad de la información. Esta restricción, declarada en el anteproyecto, hace inviable cualquier arquitectura de microservicios o despliegue remoto dentro del proyecto. Power BI permite construir una interfaz funcional e interactiva, sin requerir infraestructura adicional, lo cual es coherente con las capacidades tecnológicas disponibles en el cliente.

Se eligió procesamiento batch (por lotes) y no streaming en tiempo real, dado que el flujo operativo actual contempla la llegada periódica de resultados de laboratorio consolidados en el DWH desde el ERP corporativo. No existe un flujo de datos continuo ni sensores conectados en tiempo real al sistema de análisis, por lo que el procesamiento en streaming no agrega valor.


Una vez cargado lotes de datos proveniente del DWH, el sistema ejecuta automáticamente el siguiente flujo de procesamiento:

Preprocesamiento: eliminación de columnas irrelevantes (metadatos administrativos, variables de refrigerante), imputación de valores faltantes mediante el modelo KNN entrenado con los datos históricos, y escalamiento de variables numéricas.

Clasificación: el modelo supervisado entrenado (seleccionado entre Random Forest, Gradient Boosting u otro según métricas de validación) asigna a cada registro dos etiquetas: el nivel de severidad (Normal, Advertencia, Crítico) y el modo de falla según la condición de la muestra.

Generación de recomendaciones: a partir de la combinación de severidad y modo de falla predichos, el sistema consulta una tabla de reglas definida con el área de confiabilidad y despliega una recomendación de acción básica (por ejemplo: "Tomar nueva muestra en 250 horas", "Inspeccionar sistema de enfriamiento", "Programar cambio de aceite inmediato").

A continuación, se plasma el flujo de interacción del usuario con el artefacto analítico a desarrollar



Definición de modelos / análisis

El problema para resolver corresponde a una tarea de clasificación supervisada con enfoque predictivo, por lo que las técnicas candidatas incluyen árboles de decisión, Random Forest, Gradient Boosting, y redes neuronales.

Inicialmente, se aplicará un enfoque exploratorio descriptivo para identificar correlaciones entre variables y patrones históricos de falla. Posteriormente, se utilizarán modelos supervisados para la clasificación del modo de falla y severidad. Las técnicas de interpretación de modelos, como SHAP values, se emplearán para explicar la importancia de cada variable y facilitar la trazabilidad de los resultados.

Finalmente, se añadirá una capa prescriptiva basada en reglas derivadas de criterios expertos y metodologías de mantenimiento, con el fin de generar recomendaciones automáticas. Estas reglas podrán evolucionar hacia un sistema híbrido, donde el conocimiento experto complementa el aprendizaje automático para optimizar la priorización de acciones.

Las técnicas potenciales de Analytics a emplear comprenden:

- **Exploración y preparación de datos (EDA & ETL):** evaluar calidad, homogeneizar formatos de reportes de laboratorio, imputar/gestionar valores faltantes, normalizar unidades, enlazar con historial de mantenimiento y telemetría.
- **Modelos de aprendizaje automático supervisados** para la clasificación de estados del aceite y predicción de modos de falla y severidad de la condición.
- **Validación robusta y calibración:** aplicación de cross-validation y cuantificación de métricas específicas (precision/recall por clase, AUC, F1 por clase)
- **Análisis de importancia de predictores** para identificar el impacto de cada variable en la falla estimada y así comprender los factores de mayor influencia en el deterioro de los motores.

Datos: Fuentes, Acceso, Procesamiento (ETL)

Los datos disponibles provienen de registros históricos de análisis de aceite usado correspondientes a motores de las flotas mineras, los cuales incluyen la clasificación por modo de falla y severidad, además de variables complementarias como el ID del equipo, el ID del componente y la fecha de muestreo. Esta estructura de datos permite trazar la evolución de las condiciones de cada componente y constituye una base sólida para la construcción y validación del modelo de clasificación propuesto. En consecuencia, se considera que las fuentes de información existentes son coherentes y suficientes para abordar el problema analítico planteado.

Los datos son recolectados de forma automática y diaria a través del sistema ERP de la organización, lo que garantiza su disponibilidad, consistencia y actualización continua sin necesidad de aplicar instrumentos adicionales como encuestas o formularios. Las fuentes contienen principalmente información numérica y categórica, lo que facilita su tratamiento mediante técnicas de análisis supervisado. En cuanto a la gestión de dichas fuentes, las áreas de Mantenimiento y Tecnologías de la Información (TI) desempeñan un papel clave, siendo responsables de la recolección, administración y acceso a los datos que sustentan el desarrollo analítico del proyecto.

A continuación, se presenta el análisis exploratorio de los datos obtenidos para el desarrollo de un Sistema Clasificador de Resultados de Análisis de Aceite Usado en Motores de Maquinaria Pesada, siguiendo el flujo presentado a continuación.



Los datos aportados corresponden a los resultados de los análisis de aceite usado de motores de maquinaria pesada en los últimos 2 años de la organización. Los datos provienen del sistema ERP corporativo, que consolida de manera diaria los resultados de laboratorio de los análisis de aceite usado. Cada registro incluye variables numéricas (concentraciones de metales de desgaste, propiedades fisicoquímicas, contaminantes y aditivos) y variables categóricas (modo de falla, severidad, tipo de componente, marca y modelo del equipo).

Esta información fue suministrada en un solo archivo CSV y proviene de la base de datos de análisis del cliente, esta base de datos contiene toda la información necesaria para el desarrollo del sistema clasificador que se propone en el presente trabajo.

A continuación, se describen las columnas del conjunto de datos provisto:

Tabla 4, Descripción de variables del conjunto de datos

COLUMNA	DESCRIPCIÓN
Component ID	Identificación del componente
Asset ID	Identificación del activo (ID de la maquinaria)
Flota	Grupo de activos al que pertenece la maquinaria
Location	Grupo de activos en la base de datos de análisis de resultados de aceite usado
Component Profile	Identificación del perfil de límites que usa la base datos para análisis basado en reglas
Lubricant	Descripción del tipo de lubricante
Connection Code	Llave primaria del registro en la base de datos de análisis
Observation Type	Identificación del tipo de registro, para este caso todos son registros de análisis de fluidos
Observation Date	Fecha de toma de la muestra de aceite
Observation Code	ID del registro
Meter Reading	Lectura del medidor de servicio del componente al momento de la toma de muestra
All Time Meter Reading	Lectura del medidor de servicio de la maquinaria al momento de la toma de muestra
Component Age	Horas de servicio del componente
Observation Interval	Horas de servicio desde la última muestra de aceite para el mismo componente y maquinaria
days	Días desde la última muestra de aceite para el mismo componente y maquinaria
Observation Rating	Clasificación preliminar de severidad de la condición
Rule Based Rating	Clasificación automática realizada por el software de análisis
Lube Age	Horas de servicio del lubricante
Live	Vida del activo
Lube Drained	Indica si el lubricante fue cambiado en la última intervención del equipo
Added	Cantidad de aceite completado al componente
Assigned Condition Rating	Severidad asignada por el analista
Condition Review Notes	Notas de la revisión realizada por el analista
Further Recommendations	Recomendaciones adicionales dadas por el analista
Fault Effect	Selección del modo de falla
Reviewed	Fecha de revisión

Reviewer	Persona que realizó la revisión
Action Summary	Lista de acciones para el analista
Boro (ppm)	Contenido de boro en partes por millón (ppm)
Calcio (ppm)	Contenido de calcio en partes por millón (ppm)
Cinc (ppm)	Contenido de zinc en partes por millón (ppm)
Fosforado (ppm)	Contenido de fósforo en partes por millón (ppm)
Magnesio (ppm)	Contenido de magnesio en partes por millón (ppm)
Molibdeno (ppm)	Contenido de molibdeno en partes por millón (ppm)
SILICATOS (ppm)	Contenido de silicatos en partes por millón (ppm)
Agua (%)	Contenido de agua en porcentaje (%)
Dilución por combustible (%)	Contenido de combustible en porcentaje (%)
Hollín JOAP (Abs/cm)	Contenido de hollín en la muestra de aceite medido en absorbancia por centímetro (abs/cm)
Nitración JOAP (Abs/cm)	Contenido de nitración en la muestra de aceite medido en absorbancia por centímetro (abs/cm)
Oxidación JOAP (Abs/cm)	Contenido de oxidación en la muestra de aceite medido en absorbancia por centímetro (abs/cm)
Silicio (ppm)	Contenido de silicio en partes por millón (ppm)
Sodio (ppm)	Contenido de sodio en partes por millón (ppm)
Sulfatación JOAP (Abs/cm)	Contenido de sulfatación en la muestra de aceite medido en absorbancia por centímetro (abs/cm)
Viscosidad @ 100°C (cSt)	Viscosidad del aceite a 100°C
ISO 4406	999 > 04µ: Contenido de partículas mayores a 4 micras por cada mililitro de lubricante
ISO 4406	999 > 06µ: Contenido de partículas mayores a 6 micras por cada mililitro de lubricante
ISO 4406	999 > 14µ: Contenido de partículas mayores a 14 micras por cada mililitro de lubricante
Aluminio (ppm)	Contenido de aluminio en partes por millón (ppm)
Bario (ppm)	Contenido de bario en partes por millón (ppm)
Cadmio (ppm)	Contenido de cadmio en partes por millón (ppm)
Cobre (ppm)	Contenido de cobre en partes por millón (ppm)
Cromo (ppm)	Contenido de cromo en partes por millón (ppm)
Estaño (ppm)	Contenido de estaño en partes por millón (ppm)
Hierro (ppm)	Contenido de hierro en partes por millón (ppm)
Níquel (ppm)	Contenido de níquel en partes por millón (ppm)
Partículas Ferrosas (ppm)	Contenido de partículas ferrosas en partes por millón (ppm)
Plomo (ppm)	Contenido de plomo en partes por millón (ppm)
Color del Refrigerante	Indicador del color del refrigerante (Para muestras de refrigerante)
Glycerin (%)	Porcentaje de glicerina en el refrigerante (Para muestras de refrigerante)
Nitrito (ppm)	Contenido de nitritos en partes por millón (ppm) (Para muestras de refrigerante)
PUNTO DE EBULLICION (°C)	Punto de ebullición del refrigerante (Para muestras de refrigerante)
Sólidos Totales Disueltos (ppm)	Contenido de sólidos en suspensión en partes por millón (ppm) (Para muestras de refrigerante)
Turbidez (NTU)	Indicador de la turbidez del refrigerante (Para muestras de refrigerante)
pH	Potencial de hidrógeno pH de la muestra de refrigerante (Para muestras de refrigerante)
Titanio (ppm)	Contenido de titanio en partes por millón (ppm)
Vanadio (ppm)	Contenido de vanadio en partes por millón (ppm)

Algunas preguntas que pueden hacerse para un entendimiento inicial de los datos son:

¿Qué significa o como puede entenderse cada fila del dataframe?

Cada fila representa un resultado de análisis de aceite conteniendo la información de identificación de la muestra y de los resultados puntuales de diferentes pruebas de laboratorio a los que el lubricante usado es sometido para revelar sus propiedades y contenido de elementos de interés para estimar el estado de "salud" de la maquinaria en términos de modos de falla potenciales y el grado de severidad.

¿Qué tamaño tiene el conjunto de datos?

En la muestra de datos compartida se tiene un total de 4297 registros y 66 columnas. Todos los registros corresponden a muestras de aceite de motores de maquinaria pesada.

¿Qué tipos de datos tienen las columnas del conjunto de datos?

Se tiene un total de 46 columnas numéricas (45 de tipo flotante y 1 de tipo entero), los 20 restantes son columnas categóricas de tipo object. Esto permite conocer que el dataframe es mayoritariamente numérico.

¿Qué se encontró a nivel de completitud y cardinalidad?

Los anteriores resultados indican que se tiene un número importante de columnas prácticamente vacías, con un porcentaje de faltantes igual o cercano a 100%. Entre ellas se tienen:

- Titanio (ppm)
- Niquel (ppm)
- Cadmio (ppm)
- ISO 4406:1999 > 04μ
- Bario (ppm)
- ISO 4406:1999 > 14μ
- SILICATOS (ppm)
- PUNTO DE EBULLICION (°C)
- Glycerin (%)
- Color del Refrigerante
- pH
- Turbidez (NTU)
- Nitrito (ppm)
- Sólidos Totales Disueltos (ppm)
- Lube Age
- Action Summary

Por otra parte, también se tienen columnas con una cardinalidad muy baja, algunas incluso con cardinalidad igual a 1 lo que las hace inútiles para la construcción de modelos predictivos, tal es el caso de:

- Added
- Color del Refrigerante
- Observation Type
- Lube Drained
- Location
- Lubricant

Estas columnas al estar vacías o poseer una única categoría o valor deberán ser eliminadas del conjunto de datos.

También se realizó una revisión de la correlación de los datos faltantes haciendo uso de la librería de missingno




Ilustración 1, Matriz de correlación de datos faltantes

De esta matriz se puede establecer algunas conclusiones como sigue:

- Hay bloques de columnas con correlaciones cercanas a 1.0, lo que indica que faltan juntas porque pertenecen al mismo proceso o análisis de laboratorio.
- El grupo de variables de metales y contaminantes (Calcio, Zinc, Magnesio, etc.) forma un bloque claro: si falta una, faltan todas.
- Las variables del paquete JOAP (Hollín, Nitración, Oxidación, Sulfatación) también muestran correlaciones casi perfectas entre sí.
- Existen correlaciones negativas entre algunos bloques, lo que indica que ciertos análisis rara vez faltan al mismo tiempo; provienen de procesos distintos.
- Algunas variables administrativas (como Observation Interval o days) muestran correlaciones bajas, indicando faltantes independientes.
- En resumen, los faltantes no son aleatorios: se agrupan por módulos de análisis, lo cual tiene impacto en la imputación, el modelado, y el diagnóstico.

También se realizó un entendimiento inicial de los datos a partir de las distribuciones de las variables y su relación con una de las variables objetivo, la severidad asignada por el analista de confiabilidad.




Ilustración 2, Análisis de distribución de variables numéricas

- La mayoría de las variables muestran distribuciones fuertemente sesgadas a la derecha.
 - Hay colas largas y presencia evidente de outliers extremos en múltiples variables (metales, JOAP, sólidos disueltos, sodio, silicio, etc.).
 - Esto sugiere procesos con valores excepcionales, pero poco frecuentes, típicos de análisis de aceite contaminado o en falla.
- Outliers extremos: hay valores aislados muy altos en varios contaminantes y lecturas temporales; se debe verificar si representan fallas reales o errores de medición.
- Variables con valores casi nulos o detección limitada: varios metales (Bario, Cadmio, Níquel, Vanadio, Titanio, etc.) concentran la mayoría de observaciones igual es a cero o cercanas a cero con pocos valores detectables, posible límite de detección del instrumento
- Histogramas planos o vacíos indican alta falta de datos o constantes: ISO 4406 y algunas trazas muestran prácticamente ninguna variación, esto debido a que se trata de datos faltantes en su mayoría.
- Las variables relacionadas con tiempo o uso del equipo tienen gran dispersión.

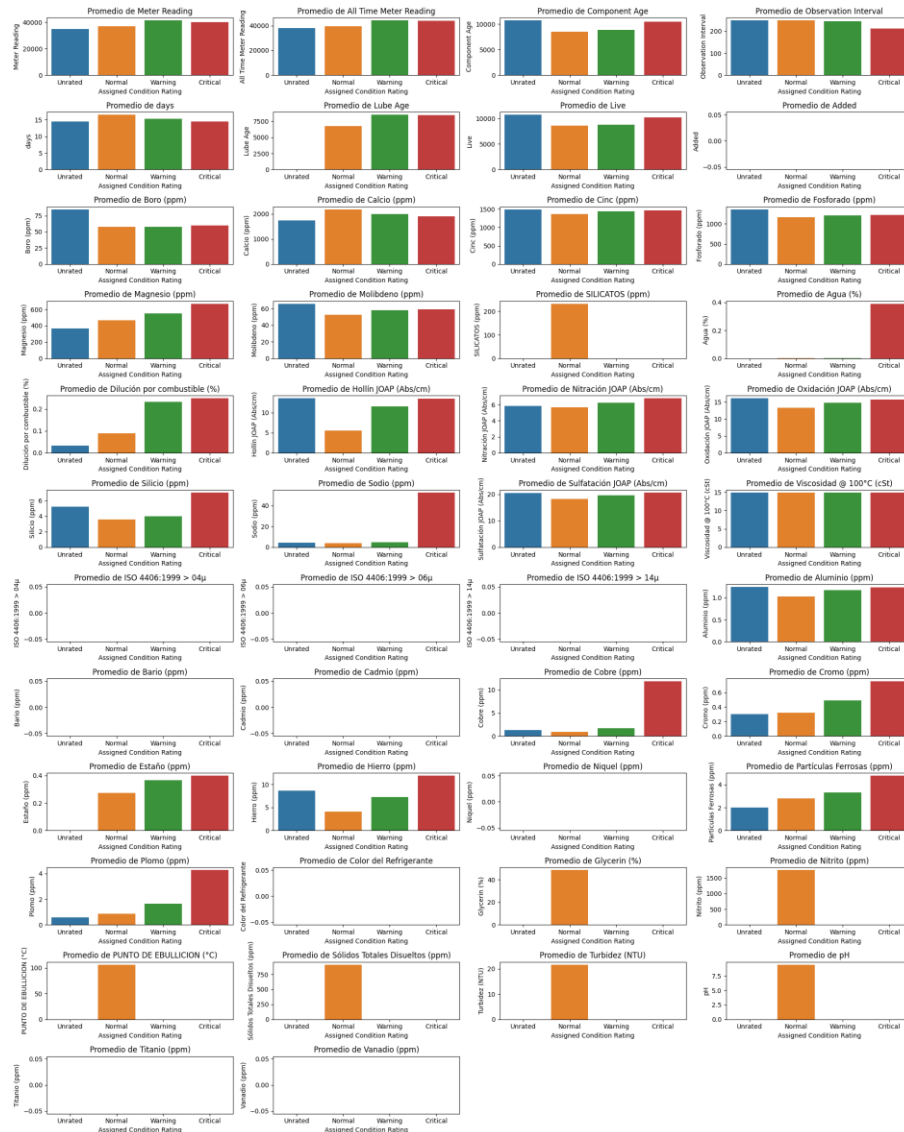


Ilustración 3, Análisis comparativo de medias de variables numéricas frente a las clases de la variable "Severidad"

- Incremento progresivo hacia "Critical": En la mayoría de los parámetros (metales, JOAP, sólidos, viscosidad, partículas), los valores promedio aumentan al pasar de Normal → Warning → Critical, validando la coherencia del sistema de clasificación. Estas variables terminan siendo fuertes candidatos a ser indicadores tempranos de desgaste o contaminación.
- JOAP (Hollín, Oxidación, Nitración, Sulfatación): Exhiben el patrón más consistente y marcado: valores significativamente más altos en Warning y, sobre todo, Critical. Son variables clave para modelar condición del aceite.
- Algunos metales con valores muy bajos: Muchos permanecen en cero o valores muy bajos en todas las categorías, lo cual limita su valor discriminante para estratificación de condición.

Técnicas de limpieza de datos

Posteriormente al entendimiento de los datos, se siguió con el proceso de limpieza de los datos, para esta fase el apoyo y acompañamiento del cliente son de vital importancia ya que con base en la experiencia y entendimiento del negocio y de los datos se toman las decisiones que impactaran positiva o negativamente la solución analítica a desarrollar

Inicialmente se eliminan del conjunto de datos aquellas variables que no tienen que ver con el análisis planteado, como aquellas que se utilizan en el análisis de refrigerante y las que se usan en el análisis de aceite hidráulico.

Variables irrelevantes para el análisis actual

Algunas columnas no aportan información útil para el estudio de condición del lubricante de los motores Diesel, ya sea porque:

- Representan metadatos administrativos
- Son información redundante
- No tienen relación directa con las variables físico-químicas a analizar

Ejemplos: Added, Lube Drained, Live, Lube Age, Observation Date, Observation Code, Observation Type, Observation Interval, Meter Reading, All Time Meter Reading, Component ID, Location, Asset ID, Connection Code, Lubricant, Component Profile, Component Age, All Time Meter Reading

Estas columnas no contienen información relevante que permita la identificación de modos de fallas generadas en el análisis de aceite, es por esta razón que las variables son excluidas de dataset con el cual se trabajara. En el caso de variables como Lube Drained, Lube Age, Component Age, en consultas con el cliente este ha expresado que en esta fase los datos contenidos en las columnas mencionadas no son confiables debido a problemas de sincronización entre diversos software que tienen en operación, se espera que en posibles desarrollos posteriores ya se cuente con esta información e incluirlas como variables de entrenamiento al modelo.

1. Tratamiento de datos faltantes

Con base en los datos faltantes identificados, se concuerda una reunión con el cliente en donde se definen las siguientes acciones bajo los datos faltantes entregada.

Tabla 5, Esquema de tratamiento de datos faltantes

Variable	% Faltantes	¿Por qué se genera?	¿Se requiere para el desarrollo del modelo?	¿Se elimina?	¿Qué tratamiento se le dará a los datos faltantes?
Action Summary	91.71515	No todos los analistas documentan acciones en el ERP; se usa otra base de datos	No	Sí	Se elimina la columna
Partículas Ferrosas (ppm)	70.351408	No en todos los motores se mide por tiempos de laboratorio	Sí	Sí	Se elimina la variable según aprobación del cliente
Fosforado (ppm)	69.979055	Inconsistencias operativas	Sí	No	Imputación por mediana
Cinc (ppm)	69.979055	Problemas de digitación o identificación	Sí	No	Imputación por mediana
Further Recommendations	66.185711	Campo no diligenciado por todos; trazabilidad en otro software	No	Sí	Se elimina

Estaño (ppm)	28.48499	Antes no se medía; ahora sí	Sí	No	Imputación por mediana
Viscosidad @ 100°C (cSt)	7.679777	Baja disponibilidad del instrumento	Sí	No	Imputación por mediana
Boro (ppm)	4.305329	Problemas de digitación o identificación	Sí	No	Imputación por mediana
Hollín JOAP (Abs/cm)	3.002094	Problemas de digitación o baja disponibilidad	Sí	No	Imputación por mediana
Dilución por combustible (%)	2.746102	Problemas operativos	Sí	No	Imputación por mediana
Agua (%)	2.466837	Baja disponibilidad del instrumento	Sí	No	Imputación por mediana
Oxidación JOAP (Abs/cm)	2.280661	Baja disponibilidad del instrumento	Sí	No	Imputación por mediana
Nitración JOAP (Abs/cm)	2.280661	Baja disponibilidad del instrumento	Sí	No	Imputación por mediana
Sulfatación JOAP (Abs/cm)	2.280661	Baja disponibilidad del instrumento	Sí	No	Imputación por mediana
Calcio (ppm)	1.81522	Problemas de digitación o identificación	Sí	No	Imputación por mediana
Magnesio (ppm)	1.81522	Problemas de digitación o identificación	Sí	No	Imputación por mediana
Molibdeno (ppm)	1.768676	Problemas operativos	Sí	No	Imputación por mediana
Silicio (ppm)	1.768676	Problemas operativos	Sí	No	Imputación por mediana
Sodio (ppm)	1.768676	Problemas operativos	Sí	No	Imputación por mediana
Aluminio (ppm)	1.768676	Problemas operativos	Sí	No	Imputación por mediana
Cromo (ppm)	1.768676	Problemas operativos	Sí	No	Imputación por mediana
Cobre (ppm)	1.768676	Problemas operativos	Sí	No	Imputación por mediana
Plomo (ppm)	1.768676	Problemas operativos	Sí	No	Imputación por mediana
Hierro (ppm)	1.117058	Problemas operativos	Sí	No	Imputación por mediana
Reviewer	0.79125	Errores de sincronización del ERP	No	Sí	Se elimina
Condition Review Notes	0.511985	No todos los analistas lo llenan	No	Sí	Se elimina
Reviewed	0.302537	Errores de sincronización	No	Sí	Se elimina
Assigned Condition Rating	0	Sin faltantes	Sí	No	Se mantiene
Fault Effect	0	Sin faltantes	Sí	No	Se mantiene
Trakka Rating	0	Sin faltantes	No	Sí	No relevante para el modelo
Observation Rating	0	Sin faltantes	No	Sí	No relevante para el modelo
Flota	0	Sin faltantes	Sí	No	Se mantiene

2. Rango de Valores numéricos de las variables en el dataset y validez

Una vez definidos los criterios para el tratamiento de los datos faltantes, se procede a revisar los rangos de valores observados durante la exploración del dataset proporcionado por el cliente. A partir de este análisis, se establecen las siguientes conclusiones.

Tabla 6, Análisis de validez de rango de las variables numéricas

Variable	Mínimo	Máximo	Comentario
Boro (ppm)	0	395,44	Valido
Calcio (ppm)	1,66	5411	No valido, valores de calcio presentan niveles a 1000, Posible Outlier
Cinc (ppm)	495,99	2154	No valido, valores de Cinc presentan niveles a 1000, Posible Outlier
Fosforado (ppm)	0	1542	No valido, valores de Fosforo presentan niveles a 1000, Posible Outlier
Magnesio (ppm)	3,16	2256	Valido
Molibdeno (ppm)	0	121,13	Valido

Agua (%)	0	14	Valido
Dilución por combustible (%)	0	10	Valido
Hollín JOAP (Abs/cm)	0	62	Valido
Nitración JOAP (Abs/cm)	0	14	Valido
Oxidación JOAP (Abs/cm)	0	33	Valido
Silicio (ppm)	0,55	95,54	Valido
Sodio (ppm)	0,17	2556	Valido
Sulfatación JOAP (Abs/cm)	0	39	Valido
Viscosidad @ 100°C (cSt)	3,431	19,4	Valido
Aluminio (ppm)	0	6,66	Valido
Cobre (ppm)	0,01	274,2	Valido
Cromo (ppm)	0	7,07	Valido
Estaño (ppm)	0	2,96	Valido
Hierro (ppm)	0	265,38	Valido
Plomo (ppm)	0	60,32	Valido

3. Tratamiento a Outlier

A partir de los outliers identificados mediante el método del rango intercuartílico (IQR), utilizando el umbral estándar de 1.5 veces el rango, se procede a cuantificar la cantidad de valores atípicos detectados en cada variable. Con esta información, se definen las acciones a seguir, las cuales serán acordadas y validadas conjuntamente con el cliente

Tabla 7, Esquema de tratamiento de datos atípicos

Variable	# Outlier	¿Se deben eliminar o Imputar?
Magnesio (ppm)	947	Si se deben imputar por los valores de mediana
Dilución por combustible (%)	530	No, Outlier corresponden a fallas , no se deben eliminar o imputar
Calcio (ppm)	455	Si se deben imputar por los valores de mediana
Plomo (ppm)	414	No, Outlier corresponden a fallas , no se deben eliminar o imputar
Aluminio (ppm)	357	No, Outlier corresponden a fallas , no se deben eliminar o imputar
Cobre (ppm)	340	No, Outlier corresponden a fallas , no se deben eliminar o imputar
Hierro (ppm)	336	No, Outlier corresponden a fallas , no se deben eliminar o imputar
Cromo (ppm)	297	No, Outlier corresponden a fallas , no se deben eliminar o imputar
Silicio (ppm)	263	No, Outlier corresponden a fallas , no se deben eliminar o imputar
Sodio (ppm)	258	No, Outlier corresponden a fallas , no se deben eliminar o imputar
Hollín JOAP (Abs/cm)	200	No, Outlier corresponden a fallas , no se deben eliminar o imputar
Estaño (ppm)	102	No, Outlier corresponden a fallas , no se deben eliminar o imputar
Molibdeno (ppm)	88	Si se deben imputar por los valores de mediana
Sulfatación JOAP (Abs/cm)	83	No, Outlier corresponden a fallas , no se deben eliminar o imputar
Oxidación JOAP (Abs/cm)	68	No, Outlier corresponden a fallas , no se deben eliminar o imputar
Viscosidad @ 100°C (cSt)	60	No, Outlier corresponden a fallas , no se deben eliminar o imputar
Boro (ppm)	41	No, Outlier corresponden a fallas , no se deben eliminar o imputar
Nitración JOAP (Abs/cm)	37	No, Outlier corresponden a fallas , no se deben eliminar o imputar

Fosforado (ppm)	21	Si se deben imputar por los valores de mediana
Cinc (ppm)	20	Si se deben imputar por los valores de mediana
Agua (%)	17	No, Outlier corresponden a fallas , no se deben eliminar o imputar

Finalmente, posterior a esta revisión y análisis se procede con la imputación de los datos bajos las reglas de negocios definidas anteriormente, para este proceso se implementa el modelo K-Vecinos en donde se busca imputar los datos a partir de similitud con las otras muestras.

Diagrama esquemático

El siguiente diagrama presenta la arquitectura funcional del sistema de análisis predictivo de aceite de motor para excavadoras Diesel. Este sistema integra seis capas, desde las fuentes de datos hasta los usuarios finales, con el objetivo de automatizar la clasificación de resultados de laboratorio, identificar modos de falla y generar recomendaciones accionables para la gestión de activos.




Ilustración 4, Diagrama esquemático

El sistema está estructurado en seis capas interrelacionadas que conforman un flujo de información de izquierda a derecha, desde los datos crudos hasta la toma de decisiones.

Datos: La capa de origen consolida cuatro consultas SQL al DWH: equipos activos, consumos de aceite, resultados de análisis de los últimos tres meses, y horas de operación de activos. Estas fuentes alimentan el proceso de transformación como insumo base.

ETL: El proceso de transformación y carga ejecuta una secuencia ordenada de ocho pasos: cálculo de nuevas variables (adiciones y cambios de aceite), cálculo de horas de operación entre muestras, imputación de datos faltantes, normalización por horas de operación y adiciones, definición del esquema de datos inicial, carga de datos base al DWH y, finalmente, carga de los datos etiquetados al DWH una vez procesados por el modelo.

Modelo: El núcleo analítico opera en dos momentos. Primero, consulta lotes de datos normalizados no etiquetados para alimentar los modelos predictivos de aprendizaje supervisado, desplegados en máquina virtual. Como resultado produce datos normalizados y etiquetados, que retornan al ETL para su carga al DWH. Adicionalmente, un BI Dashboard expone los resultados del modelo hacia las capas de funcionalidad y requerimientos.

Funcionalidad: La plataforma expone cinco capacidades principales al usuario: consulta de resultados de muestras de aceite por flota, equipo y fechas; clasificación del modo de falla y severidad; consulta de factores relevantes; acciones recomendadas; y estimación de costos evitados.

Requerimientos: Los requerimientos del negocio están alineados directamente con las funcionalidades del sistema. Incluyen el análisis automatizado de resultados de laboratorio, la clasificación bajo el esquema SACODE (Salud, Contaminación y Desgaste), la visualización de tendencias recientes, la identificación del modo de falla predominante y su severidad, la visualización de factores relevantes para la clasificación, la generación de acciones recomendadas y el cálculo de costos evitados. Los requerimientos destacados en amarillo corresponden a aquellos con mayor relevancia estratégica o que requieren atención prioritaria.

Usuarios: El sistema atiende a dos perfiles: el Analista de Confiabilidad, enfocado en el análisis técnico de los resultados, y el Gerente de Gestión de Activos, orientado a la toma de decisiones estratégicas sobre el mantenimiento de la flota.

MockUp / Storyboard

El dashboard es la interfaz principal del sistema. Está diseñado para que tanto el Analista de Confiabilidad como el Gerente de Gestión de Activos puedan consultar, filtrar y analizar los resultados del modelo predictivo de forma autónoma, sin necesidad de conocimientos técnicos en ciencia de datos o análisis de aceite.




Ilustración 5. MockUp del dashboard a implementar

Paso 1: Seleccionar el contexto de análisis (panel izquierdo)

Los tres filtros ubicados en la columna izquierda definen el alcance de toda la información desplegada en el dashboard:

- **Flota:** permite seleccionar una flota específica o ver todas (All). Útil cuando la operación maneja múltiples sitios o contratos.
- **Equipo:** filtra por excavadora individual. Al seleccionar un equipo, todos los indicadores, gráficas y recomendaciones se actualizan para mostrar únicamente su información.
- **Período:** define el rango de fechas de análisis mediante un control deslizante o ingresando fechas manualmente.

Una vez configurados los filtros, se presiona Aplicar filtros para actualizar el dashboard.

Ejemplo: El analista quiere revisar el estado del equipo E07 durante el primer trimestre de 2026. Selecciona Flota: **EX3400**, Equipo: **E07**, ajusta el período entre **01/01/2026** y **31/03/2026** y presiona Aplicar filtros.

Paso 2: Revisar los indicadores de resumen (fila superior)

La fila de tarjetas en la parte superior ofrece una vista ejecutiva del estado actual:

- **Equipos monitoreados:** total de máquinas activas en el sistema.
- **Muestras analizadas:** volumen procesado en el período, con comparativo respecto al período anterior (ej. +10%).
- **Costos evitados:** estimación en USD del ahorro generado por las intervenciones preventivas detectadas por el modelo.
- **Muestras etiquetadas como advertencia / críticas:** cantidad de muestras que el modelo clasificó con algún nivel de alerta.
- **Casos completados:** intervenciones o seguimientos ya cerrados.

Ejemplo: El Gerente de Gestión de Activos revisa la vista general (**All / All**) y detecta que hay 12 muestras críticas activas. Decide profundizar en cuáles equipos las generaron antes de su reunión semanal de mantenimiento.

Paso 3: Analizar el historial de resultados (tabla central)

La tabla muestra el detalle de cada muestra procesada, con las columnas:

- **Fecha:** cuándo se tomó la muestra.
- **Salud / Contaminación / Desgaste:** semáforos de color (verde = normal, rojo = alerta) para cada categoría SACODE.
- **Modo de falla:** clasificación predictiva del tipo de problema detectado (ej. Desgaste metálico, Aceite degradado, Dilución).
- **Criticidad:** nivel de urgencia de la intervención recomendada.

Ejemplo: El analista identifica que la muestra del **15-Feb-2026** tiene alerta roja en Salud y en Desgaste, con modo de falla "Aceite degradado" y criticidad alta. Esto le indica que ese equipo requiere atención prioritaria antes de la próxima muestra.

Paso 4: Interpretar los gráficos de tendencia

Los tres gráficos de línea muestran la evolución temporal de los indicadores principales de cada categoría SACODE:

- **Indicadores de Salud:** parámetros como viscosidad, índice de acidez o basicidad del aceite.
- **Indicadores de Contaminación:** niveles de partículas externas como tierra, agua o combustible.
- **Indicadores de Desgaste:** concentración de metales de desgaste como hierro, cobre o plomo.

Las tendencias al alza en estos gráficos anticipan problemas antes de que se vuelvan críticos.

Ejemplo: El analista observa que los indicadores de Desgaste del equipo E07 muestran una tendencia creciente sostenida desde marzo. Aunque la última muestra aún no supera el umbral crítico, programa una inspección preventiva para la semana siguiente.

Paso 5: Consultar el gráfico de modos de falla y los factores relevantes

El gráfico de torta (panel derecho superior) muestra la distribución proporcional de los modos de falla detectados en el período seleccionado. Permite identificar si hay un tipo de problema dominante en la flota.

El gráfico de barras de factores relevantes muestra qué variables analíticas tuvieron mayor peso en la clasificación del modelo (ej. SA-Ox, CO-Fuel, DE-Fe). Esto orienta al analista sobre qué parámetros monitorear con mayor atención.

Ejemplo: El analista observa que el 40% de las fallas en el trimestre corresponden a Entrada de tierra y Desgaste metálico. Concluye que puede haber un problema sistémico de sellado en la flota y solicita una revisión de los filtros de todos los equipos.

Paso 6: Leer y actuar sobre las recomendaciones

El panel de Recomendaciones (parte inferior derecha) presenta las acciones sugeridas automáticamente por el modelo para el equipo y período seleccionados. Las recomendaciones son específicas al contexto del filtro aplicado.

Ejemplo: Para el equipo E07, el sistema recomienda inspeccionar los filtros de aceite en busca de partículas metálicas y programar una toma de muestras a las 50 horas de operación. El analista registra estas acciones en el ERP y marca el caso como en seguimiento.

Flujo de uso típico por perfil

Perfil	Frecuencia de uso	Foco principal
Analista de confiabilidad	Diaria / por cada lote de muestras	Historial, tendencias, factores relevantes
Equipo de gerencia	Semanal / reuniones de control	Indicadores de resumen, modos de falla, costos evitados

Referencias

- Jardine, A., Lin, D., & Banjevic, D. (2005). A review on machinery diagnostics and prognostics implementing condition-based maintenance. *Elsevier Ltd*, 28.
- Keartland, S., & Van Zyl, T. (2020). Automating predictive maintenance using oil. *IEEE Xplore*, 6.
- Rao, X., Sheng, C., & Guo, Z. (2021). A review of online condition monitoring and maintenance strategy for cylinder liner-piston rings of diesel engines. *Elsevier Ltd*, 23.
- Shah, R., Jaramillo, R., Thomas, G., Rayhan, T., Hossain, N., Kchaou, M., . . . Rosenkranz, A. (2025). Artificial Intelligence and Machine Learning in Tribology: Selected Case Studies and Overall Potential. *ADVANCED SCIENCE NEWS*, 15.
- Tian, Z. (2009). An artificial neural network method for remaining useful life prediction of equipment subject to condition monitoring. *Springer Science+Business Media*, 11.
- Wakirua, J., Pintelona, L., Muchiri, P., & Chemweno, P. (2018). A review on lubricant condition monitoring information analysis for maintenance decision support. *Elsevier Ltd.*, 25.

Nota de Confidencialidad

Este documento contiene información interna de carácter confidencial. Su contenido, incluyendo datos, resultados y análisis, es exclusivo para uso autorizado dentro de la organización. Se prohíbe su reproducción o divulgación sin permiso previo y por escrito de los autores y/o la entidad propietaria de la información.

© 2026. Todos los derechos reservados. Uso exclusivo académico e interno.